UNIVERSIDADE FEDERAL DA FRONTEIRA SUL
CAMPUS CHAPECÓ
CURSO DE CIÊNCIA DA COMPUTAÇÃO

MARCO AURÉLIO LUNARDI

ENGENHARIA DE DADOS PARA GESTÃO EDUCACIONAL: UMA ARQUITETURA *SERVERLESS* PARA INDICADORES DE TRAJETÓRIA DISCENTE NOS DADOS ABERTOS DA UFFS

CHAPECÓ
2026

MARCO AURÉLIO LUNARDI

ENGENHARIA DE DADOS PARA GESTÃO EDUCACIONAL: UMA ARQUITETURA *SERVERLESS* PARA INDICADORES DE TRAJETÓRIA DISCENTE NOS DADOS ABERTOS DA UFFS

Trabalho de Conclusão de Curso apresentado ao Curso de Ciência da Computação da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Raquel Aparecida Pegoraro

CHAPECÓ
2026

Lunardi, Marco Aurélio

ENGENHARIA DE DADOS PARA GESTÃO EDUCACIONAL: UMA ARQUITETURA *SERVERLESS* PARA INDICADORES DE TRAJETÓRIA DISCENTE NOS DADOS ABERTOS DA UFFS / Marco Aurélio Lunardi - 2026.

51 f.

Orientador: Raquel Aparecida Pegoraro

Trabalho de Conclusão de Curso (Graduacão) - Universidade Federal da Fronteira Sul, Curso de Ciência da Computação, Chapecó, SC, 2026.

1. Engenharia de Dados 2. Dados Abertos 3. Análise de Dados 4. Computação em Nuvem 5. Gestão Universitária I. Pegoraro, Raquel Aparecida, orient. II. Universidade Federal da Fronteira Sul. III. Título.

MARCO AURÉLIO LUNARDI

ENGENHARIA DE DADOS PARA GESTÃO EDUCACIONAL: UMA ARQUITETURA *SERVERLESS* PARA INDICADORES DE TRAJETÓRIA DISCENTE NOS DADOS ABERTOS DA UFFS

Trabalho de Conclusão de Curso apresentado ao Curso de Ciência da Computação da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Raquel Aparecida Pegoraro

Este Trabalho de Conclusão de Curso foi avaliado e aprovado pela banca avaliadora em: 02/07/2026.

BANCA AVALIADORA

Raquel Aparecida Pegoraro - UFFS

Claunir Pavan - UFFS

Felipe Grando - UFFS

DEDICATÓRIA

Dedico este trabalho aos meus pais e à minha namorada, cujo amor, apoio e incentivo incondicionais foram a base para que eu chegasse até aqui.

AGRADECIMENTOS

Aos meus pais, Nedilson Lunardi e Guiomar Lunardi, por serem minha maior fonte de força.

À minha namorada, Eduarda Lazzaretti da Silva, pela compreensão nas inúmeras horas de ausência dedicadas aos estudos, e pelo apoio incondicional.

Aos meus amigos, que acompanharam toda essa jornada, pelo apoio constante e pelos momentos de descontração que foram essenciais para manter o equilíbrio durante o curso.

À minha orientadora, Profª Raquel Aparecida Pegoraro, por toda a paciência, pelas valiosas discussões e pelo direcionamento essencial desde a definição do escopo deste projeto.

Aos professores do curso de Ciência da Computação da UFFS, que construíram a base da minha formação e me forneceram as ferramentas necessárias para atuar profissionalmente.

RESUMO

A gestão eficiente de Instituições de Ensino Superior (IES) públicas brasileiras demanda a transformação de grandes volumes de dados em indicadores acionáveis. A Universidade Federal da Fronteira Sul (UFFS) disponibiliza dados acadêmicos por meio do Portal de Dados Abertos, em conformidade com a Lei de Acesso à Informação (Lei nº 12.527/2011). Este trabalho descreve o desenvolvimento de um pipeline automatizado capaz de extrair, limpar e integrar os dados abertos da UFFS, gerando indicadores gerenciais e um painel analítico interativo focado no Campus Chapecó. O painel organiza os indicadores em três dimensões: retrato demográfico e ingresso, fluxo acadêmico (evasão e retenção) e desempenho e gargalos curriculares, permitindo que coordenadores de curso e diretores de campus tomem decisões estratégicas baseadas em evidências. O trabalho demonstra a viabilidade técnica e institucional de uma solução de *analytics* educacional moderna, reproduzível e sustentável para universidades federais brasileiras.

Palavras-Chave: Engenharia de Dados, Dados Abertos, Análise de Dados, Computação em Nuvem, Gestão Universitária.

ABSTRACT

The efficient management of Brazilian public Higher Education Institutions (HEIs) demands the transformation of large volumes of data into actionable indicators. The Federal University of Southern Frontier (UFFS) makes academic data available through its Open Data Portal, in compliance with the Access to Information Law (Law nº 12.527/2011). This work describes the development of an automated pipeline capable of extracting, cleaning, and integrating UFFS open data, generating managerial indicators and an interactive analytical dashboard focused on the Chapecó campus. The dashboard organizes the indicators into three dimensions: demographic profile and admission, academic flow (dropout and retention), and performance and curricular bottlenecks, allowing course coordinators and campus directors to make evidence-based strategic decisions. The study demonstrates the technical and institutional viability of a modern, reproducible, and sustainable educational *analytics* solution for Brazilian federal universities.

Keywords: Data Engineering, Open Data, Data Analysis, Cloud Computing, University Management.

LISTA DE FIGURAS

2.1 Amostra visual dos dados brutos do conjunto de dados de perfil discente. 19
2.2 Amostra visual dos dados brutos do conjunto de dados de turmas ofertadas. 20
2.3 Amostra visual dos dados brutos do conjunto de dados de histórico de notas. 21
4.1 Diagrama da arquitetura de dados e serviços do *pipeline* analítico. . . . 37

LISTA DE SIGLAS

AC – Ampla Concorrência

API – *Application Programming Interface* (Interface de Programação de Aplicações)

AWS – *Amazon Web Services*

BI – *Business Intelligence* (Inteligência de Negócios)

CCR – Componente Curricular

CGU – Controladoria-Geral da União

CI/CD – *Continuous Integration and Continuous Delivery* (Integração e Entrega Contínuas)

CKAN – *Comprehensive Knowledge Archive Network*

CNPq – Conselho Nacional de Desenvolvimento Científico e Tecnológico

CPU – *Central Processing Unit* (Unidade Central de Processamento)

CSV – *Comma-Separated Values* (Valores Separados por Vírgula)

DAE – Dados Abertos Educacionais

EDA – *Exploratory Data Analysis* (Análise Exploratória de Dados)

ELT – *Extract, Load, Transform* (Extrair, Carregar, Transformar)

ETL – *Extract, Transform, Load* (Extrair, Transformar, Carregar)

GCP – *Google Cloud Platform*

HTTP – *Hypertext Transfer Protocol* (Protocolo de Transferência de Hipertexto)

IAG – Inteligência Artificial Generativa

IES – Instituição de Ensino Superior

INDA – Infraestrutura Nacional de Dados Abertos

INEP – Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira

JSON – *JavaScript Object Notation*

LAI – Lei de Acesso à Informação

LGPD – Lei Geral de Proteção de Dados

MDS – *Modern Data Stack*

NIST – *National Institute of Standards and Technology*

OLAP – *Online Analytical Processing* (Processamento Analítico Online)

OLTP – *Online Transaction Processing* (Processamento Transacional Online)

PaaS – *Platform as a Service* (Plataforma como Serviço)

PDA – Plano de Dados Abertos

PSS – Processo Seletivo Especial

RAM – *Random Access Memory* (Memória de Acesso Aleatório)

RDF – *Resource Description Framework*

REST – *Representational State Transfer* (Transferência de Estado Representacional)

S3 – *Simple Storage Service*

SaaS – *Software as a Service* (Software como Serviço)

SGA – Sistema de Gestão Acadêmica

SIC – Serviço de Informação ao Cidadão

SIGAA – Sistema Integrado de Gestão de Atividades Acadêmicas

SISU – Sistema de Seleção Unificada

SQL – *Structured Query Language* (Linguagem de Consulta Estruturada)

TCC – Trabalho de Conclusão de Curso

TI – Tecnologia da Informação

TTL – *Time-To-Live* (Tempo de Vida)

UFFS – Universidade Federal da Fronteira Sul

UFMT – Universidade Federal de Mato Grosso

UFRN – Universidade Federal do Rio Grande do Norte

UNESP – Universidade Estadual Paulista

SUMÁRIO

1 INTRODUÇÃO 13
1.1 PROBLEMA 13
1.2 OBJETIVOS 13
1.2.1 OBJETIVO GERAL 13
1.2.2 OBJETIVOS ESPECÍFICOS 14
1.3 JUSTIFICATIVA 14

2 FUNDAMENTAÇÃO TEÓRICA 16
2.1 TRANSPARÊNCIA E DADOS ABERTOS 16
2.1.1 LEI DE ACESSO À INFORMAÇÃO (LEI Nº 12.527/2011) 17
2.1.2 POLÍTICA DE DADOS ABERTOS NO GOVERNO FEDERAL 17
2.1.3 PLATAFORMA CKAN COMO REPOSITÓRIO DE DADOS ABERTOS INSTITUCIONAIS 17
2.1.4 PORTAL DE DADOS ABERTOS DA UFFS 18
2.1.4.1 DADOS ACADÊMICOS 19
2.2 ENGENHARIA DE DADOS 21
2.2.1 MODERN DATA STACK E O PARADIGMA ELT 21
2.2.2 ARQUITETURA MEDALHÃO 22
2.2.3 COMPUTAÇÃO EM NUVEM 23
2.2.4 O PARADIGMA *SERVERLESS* 23
2.2.5 PROCESSAMENTO ANALÍTICO E ARMAZENAMENTO COLUNAR 24
2.2.6 ORQUESTRAÇÃO DE *PIPELINES* E ARQUITETURAS ORIENTADAS A EVENTOS 25
2.2.7 PROCESSAMENTO VETORIZADO E O PADRÃO APACHE ARROW 26
2.2.8 DETALHAMENTO DAS TECNOLOGIAS ADOTADAS 26
2.3 O DOMÍNIO DO NEGÓCIO: INDICADORES INSTITUCIONAIS E EDUCACIONAIS 28
2.3.1 FLUXO ACADÊMICO: EVASÃO, RETENÇÃO E DIPLOMAÇÃO 29
2.3.2 PERFIL DISCENTE E POLÍTICAS DE PERMANÊNCIA 29

3 TRABALHOS CORRELATOS 31

3.1 ABORDAGENS DE BI TRADICIONAL NA GESTÃO DISCENTE 31
3.2 PROCESSAMENTO DE DADOS EDUCACIONAIS VIA ETL TRADICIONAL 31
3.3 ANALYTICS EDUCACIONAL COM FERRAMENTAS *OPEN-SOURCE* MODERNAS 32
3.4 INTEGRAÇÃO E CONSUMO DE DADOS VIA PORTAIS CKAN 33

4 METODOLOGIA 35
4.1 CARACTERIZAÇÃO DA PESQUISA 35
4.2 ETAPAS DA PESQUISA 35
4.2.1 ESTUDO EXPLORATÓRIO E ANÁLISE DAS BASES DE DADOS DISPONÍVEIS 36
4.2.2 DEFINIÇÃO DA ARQUITETURA DA SOLUÇÃO E *STACK* DE DESENVOLVIMENTO 37
4.2.3 GERENCIAMENTO DE RISCOS 38
4.2.3.1 OBTENÇÃO DE DADOS VIA LEI DE ACESSO À INFORMAÇÃO (FALA.BR) 38
4.2.3.2 SEGURANÇA DE INFRAESTRUTURA E GOVERNANÇA DE RECURSOS EM NUVEM 39
4.2.4 INGESTÃO DE DADOS E TRATAMENTO DE RESTRIÇÕES DA API 39
4.2.5 *PIPELINE* DE TRATAMENTO E ARMAZENAMENTO (CAMADAS BRONZE E *SILVER*) 40
4.2.6 MODELAGEM ANALÍTICA E CAMADA DE SERVIÇO (CAMADA *GOLD*) . 41
4.2.7 DESENVOLVIMENTO E HOSPEDAGEM DO PAINEL ANALÍTICO 43
4.2.8 ORQUESTRAÇÃO, AUTOMAÇÃO E OBSERVABILIDADE 43
4.3 DEFINIÇÃO DAS ANÁLISES E MÉTRICAS DO PAINEL 45
4.3.1 VISÃO 1: RETRATO DEMOGRÁFICO E INGRESSO 45
4.3.2 VISÃO 2: FLUXO ACADÊMICO (EVASÃO E RETENÇÃO) 45
4.3.3 VISÃO 3: DESEMPENHO E GARGALOS CURRICULARES 46
4.3.4 CLÁUSULA DE FLEXIBILIZAÇÃO DO ESCOPO ANALÍTICO 46
4.4 DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL 47
4.5 GESTÃO E DISPONIBILIZAÇÃO DE DADOS E CÓDIGOS 47
4.6 CRONOGRAMA DE EXECUÇÃO 47

REFERÊNCIAS 49

1. INTRODUÇÃO

A gestão eficiente das Instituições de Ensino Superior (IES) públicas brasileiras tem se tornado cada vez mais dependente da capacidade de transformar dados brutos em informações acionáveis. Universidades como a Universidade Federal da Fronteira Sul (UFFS) geram registros que englobam matrículas, histórico de notas, controle de evasão discente e dados de fomento à pesquisa e extensão.

Com o advento da Lei de Acesso à Informação (Lei nº 12.527/2011) (BRASIL, 2011) e do avanço das políticas de dados abertos no governo federal, essas instituições passaram a disponibilizar conjuntos de dados catalogados e acessíveis à sociedade, garantindo a transparência governamental. A UFFS utiliza a plataforma CKAN (*Comprehensive Knowledge Archive Network*) para centralizar e disponibilizar seus conjuntos de dados abertos de forma padronizada (UNIVERSIDADE FEDERAL DA FRONTEIRA SUL - UFFS, 2026).

Contudo, a simples disponibilização desses dados não implica em sua imediata utilidade analítica. A ausência de um processamento contínuo e integrado – que unifique dados acadêmicos e administrativos – dificulta a extração de métricas de desempenho e atrasa a tomada de decisão pelos coordenadores de curso e diretores de *campus*, evidenciando a necessidade de soluções tecnológicas baseadas em Engenharia de Dados.

1.1 Problema

Como transformar os dados acadêmicos das bases do Portal de Dados Abertos da UFFS em indicadores gerenciais consistentes e atualizados que auxiliem a tomada de decisão no *Campus* Chapecó?

1.2 Objetivos

1.2.1 Objetivo Geral

O objetivo geral deste trabalho é desenvolver um *pipeline* automatizado de Engenharia de Dados utilizando conceitos de *Modern Data Stack*, capaz de extrair,

limpar e integrar os dados acadêmicos abertos da UFFS, gerando indicadores gerenciais e painéis analíticos focados no *Campus* Chapecó.

1.2.2 Objetivos Específicos

Para alcançar o objetivo proposto, foram estabelecidos os seguintes objetivos específicos:

- Realizar a Análise Exploratória de Dados (EDA — *Exploratory Data Analysis*) nos conjuntos de dados acadêmicos do Portal de Dados Abertos da UFFS focados no domínio discente e no histórico de notas, atestando sua granularidade e viabilidade técnica.
- Consumir a API de busca do CKAN (`datastore_search_sql`) para viabilizar a extração paginada e automatizada dos dados via requisições HTTP *RESTful*.
- Projetar uma arquitetura de dados escalável, orientada ao modelo Medalhão (camadas Bronze, *Silver* e *Gold*) em ambiente de nuvem (*serverless*).
- Desenvolver um painel analítico interativo para a gestão do *Campus* Chapecó, focado no monitoramento estratégico do perfil demográfico de ingresso, da trajetória discente (índices de evasão e retenção) e na identificação estatística de gargalos curriculares nas disciplinas.

1.3 Justificativa

A relevância deste trabalho se manifesta na otimização da gestão universitária. O atual cenário tecnológico demanda que as decisões estratégicas nas esferas públicas sejam tomadas com base em evidências (cultura *data-driven*).

Ao organizar os dados brutos em uma infraestrutura moderna e escalável, este projeto entrega uma camada de inteligência analítica que permite mapear, por exemplo, quais disciplinas possuem as maiores taxas históricas de reprovação (os “gargalos” do curso) ou qual o percentual de inclusão social discente via cotas ao longo dos anos. Tais informações são fundamentais para que a coordenação pedagógica aloque recursos de monitoria de forma mais eficiente e desenvolva políticas de permanência estudantil com maior assertividade.

Além disso, do ponto de vista tecnológico, o trabalho demonstra na prática a aplicação de conceitos de ponta em processamento de dados (como arquiteturas *serverless* e *modern data stack*), consolidando os conhecimentos de Ciência da Computação para a resolução de um problema real da educação pública.

Por fim, ressalta-se a sustentabilidade financeira da solução proposta. Ao fundamentar a arquitetura analítica integralmente em ferramentas de código aberto (*open-source*) e serviços em nuvem com planos gratuitos permanentes, o projeto viabiliza a adoção e a operação contínua da infraestrutura pela universidade. Essa estratégia isenta a instituição de custos recorrentes com transferência de dados ou licenciamento de *software*, entregando inovação tecnológica diretamente alinhada à realidade orçamentária do setor público.

2. FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos e tecnologias que fundamentam o desenvolvimento deste trabalho. Inicialmente, são abordados os princípios de transparência pública, dados abertos e as características da plataforma CKAN. Em seguida, contextualiza-se o cenário moderno de Engenharia de Dados, com ênfase no processo ELT (*Extract, Load, Transform*) e na Arquitetura Medalhão em ambiente de nuvem. Por fim, detalha-se o domínio de negócio da aplicação, delimitando os principais indicadores institucionais e pedagógicos que norteiam a solução.

2.1 Transparência e dados abertos

O conceito de Dados Abertos (*Open Data*) refere-se a dados que podem ser livremente usados, reutilizados e redistribuídos por qualquer pessoa, sujeitando-se, no máximo, à exigência de atribuição da fonte e ao compartilhamento pelas mesmas regras (OPEN KNOWLEDGE FOUNDATION, 2012).

Segundo a fundação (OPEN KNOWLEDGE FOUNDATION, 2012), a essência do que torna um dado aberto pode ser resumida em três pontos fundamentais:

- **Disponibilidade e acesso:** Os dados devem estar disponíveis como um todo, a um custo de reprodução razoável, e preferencialmente passíveis de serem baixados pela internet em formatos convenientes e modificáveis.
- **Reutilização e redistribuição:** Os dados devem ser fornecidos sob termos que permitam a sua reutilização e redistribuição, inclusive possibilitando a combinação com outros conjuntos de dados.
- **Participação universal:** Todos devem ser capazes de usar, reutilizar e redistribuir a informação, sem que haja discriminação contra grupos, pessoas ou áreas de atuação, o que significa que restrições de uso comercial ou exclusivamente educativo excluem os dados do conceito de “abertos”.

Segundo o Governo Federal (BRASIL, 2026b), “Dados Abertos são uma metodologia para a publicação de dados do governo em formatos reutilizáveis, visando o aumento da transparência e maior participação política por parte do cidadão, além de gerar diversas aplicações desenvolvidas colaborativamente pela sociedade”.

2.1.1 Lei de Acesso à Informação (Lei nº 12.527/2011)

No Brasil, o principal marco regulatório para a consolidação da transparência pública foi a promulgação da Lei de Acesso à Informação (LAI), Lei nº 12.527/2011 (BRASIL, 2011). A LAI inverteu a lógica histórica do sigilo na administração pública brasileira, estabelecendo a publicidade como regra e o sigilo como exceção.

O texto legal obriga os órgãos e as entidades públicas, incluindo as instituições de ensino superior (IES), a promoverem a divulgação de informações de interesse coletivo em canais de fácil acesso. Essa obrigatoriedade visa aproximar o cidadão da máquina pública, viabilizando o controle social e estimulando a gestão participativa (BRASIL, 2011).

2.1.2 Política de dados abertos no governo federal

Para operacionalizar a LAI no ambiente digital, o governo federal instituiu a Política de Dados Abertos do Poder Executivo Federal por meio do Decreto nº 8.777/2016 (BRASIL, 2016). Posteriormente, visando estruturar a governança dessas informações, o Decreto nº 9.903/2019 estabeleceu que a gestão dessa política cabe à Controladoria-Geral da União (CGU), sendo executada por meio da Infraestrutura Nacional de Dados Abertos (INDA) (BRASIL, 2019).

Essa infraestrutura define as diretrizes técnicas e padronizadas para a publicação de dados em formatos abertos e legíveis por máquina, garantindo a interoperabilidade entre os sistemas governamentais. Adicionalmente, a referida política fomenta a criação de Planos de Dados Abertos (PDA) pelas universidades federais, instituindo a obrigatoriedade de catalogarem e atualizarem periodicamente seus conjuntos de dados institucionais (BRASIL, 2016; BRASIL, 2019).

2.1.3 Plataforma CKAN como repositório de dados abertos institucionais

Para estruturar e dar publicidade aos seus catálogos de dados conforme exige a legislação, diversos órgãos governamentais adotam o CKAN. A plataforma consiste em um sistema de código aberto líder mundial no gerenciamento de portais de dados públicos. Sua principal vantagem analítica reside na extensão *DataStore*, que armazena recursos tabulares em bancos de dados relacionais e expõe APIs. O

uso de *endpoints* permite a execução de consultas HTTP diretas, otimizando a extração de dados e dispensando o *download* de arquivos massivos (CKAN, 2026).

No cenário brasileiro, a adoção do CKAN como padrão tecnológico é liderada pelo governo federal, que utiliza a ferramenta como a infraestrutura-base do Portal Brasileiro de Dados Abertos (`dados.gov.br`). Segundo o relato oficial da equipe de desenvolvimento do portal, essa escolha estratégica atendeu não apenas às diretrizes da Infraestrutura Nacional de Dados Abertos (INDA), mas também às políticas governamentais de Tecnologia da Informação (TI) que exigem a priorização de *software* livre em detrimento de soluções proprietárias (CKAN BRASIL, 2012).

A ferramenta atua como um ponto centralizador em uma arquitetura distribuída, unificando o catálogo de metadados de ministérios, agências reguladoras e instituições federais de ensino, as quais mantêm a responsabilidade sobre suas próprias bases (CKAN BRASIL, 2012). Ao padronizar o ecossistema sob o CKAN em nível federal, simplifica-se o processo de federação de dados — permitindo que portais locais colham e enviem suas estruturas automaticamente para o indexador nacional —, o que consolida a transparência pública ativa e viabiliza a interoperabilidade técnica exigida pela Lei de Acesso à Informação (CKAN BRASIL, 2012).

2.1.4 Portal de dados abertos da UFFS

Alinhada às diretrizes do Decreto nº 8.777/2016 (BRASIL, 2016), a Universidade Federal da Fronteira Sul (UFFS) implementou o seu próprio Portal de Dados Abertos. Essa iniciativa foi formalizada a partir da publicação do Plano de Dados Abertos da UFFS, em janeiro de 2017. De acordo com a instituição, o plano segue os princípios de transparência na gestão administrativa e acadêmica, buscando disseminar dados e informações tanto para a comunidade interna quanto externa. O objetivo central do portal é propiciar um maior suporte à tomada de decisão pelos gestores públicos e estimular o controle social (UNIVERSIDADE FEDERAL DA FRONTEIRA SUL - UFFS, 2017).

Tecnologicamente, o portal da universidade utiliza a plataforma CKAN e atua como o repositório central oficial da instituição, congregando as bases de dados geradas pelos diversos setores dos *campi* (UNIVERSIDADE FEDERAL DA FRONTEIRA SUL - UFFS, 2026). A plataforma permite que pesquisadores e desenvolvedores consumam essas informações institucionais de forma estruturada, respeitando as diretrizes de anonimização exigidas pela Lei Geral de Proteção de Dados (LGPD) (BRASIL, 2018).

2.1.4.1 Dados acadêmicos

O portal de dados abertos disponibilizado pela UFFS é composto por recursos tabulares organizados por domínios. No escopo discente e de fluxo acadêmico, três conjuntos de dados (*datasets*) principais contêm as variáveis necessárias para o mapeamento da trajetória do estudante no *campus* Chapecó, atuando como a base de dados bruta desta pesquisa (UNIVERSIDADE FEDERAL DA FRONTEIRA SUL - UFFS, 2026):

- **Perfil Discente:** Este conjunto fornece o mapeamento sociodemográfico e o histórico de vínculo de cada estudante. Ele abrange variáveis críticas como o tipo de discente (regular ou especial), raça, sexo/gênero, ano e semestre de ingresso, *campus* de oferta e a situação atual de matrícula no curso. Além disso, detalha a forma de ingresso (como SISU, Processo Seletivo Simplificado ou transferências) e discrimina explicitamente a modalidade de cota de inscrição — reunindo grupos de ampla concorrência (AC) e as diferentes ações afirmativas de escola pública, renda e cor, tais como L1, L2, L5, L6, L9, L10, L13 e L14.

Figura 2.1 – Amostra visual dos dados brutos do conjunto de dados de perfil discente.

Data | Statistics | File Contents — Showing 1 to 50 of many records

#	_id	tipo_discente	raca	genero	ano_ingresso	semestre_ingresso	forma_ingresso	modalidade_inscricao	modalidade_vaga_ocupada	sit_matricula	nome_campus	cod_uffs	nome_curso	turno	matriz	data_atualizacao
1	1	REGULAR	Indígeno	M	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		ATIVO	Chapecó	1310	Engenharia Civil	Matutino e Vespertino	2025/2	2026-05-18T02:30:16.000Z
2	2	REGULAR	Pardo	M	2026	1	SiSU	AC		ATIVO	Chapecó	1610	Ciências Econômicas	Noturno	2025/1	2026-05-18T02:30:16.000Z
3	3	REGULAR	Negro	M	2026	1	PRÓ-IMIGRANTE	N/A		ATIVO	Chapecó	1100	Ciência Da Computação	Vespertino	2025/1	2026-05-18T02:30:16.000Z
4	4	REGULAR	Branco	M	2026	1	SiSU	AC		ATIVO	Chapecó	1600	Administração	Matutino	2017/1	2026-05-18T02:30:16.000Z
5	5	REGULAR	Pardo	M	2026	1	RETORNO DE GRADUADO	N/A		ATIVO	Chapecó	1610	Ciências Econômicas	Noturno	2025/1	2026-05-18T02:30:16.000Z
6	6	REGULAR	Pardo	M	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		ATIVO	Chapecó	1310	Engenharia Civil	Matutino e Vespertino	2025/2	2026-05-18T02:30:16.000Z
7	7	REGULAR	Branco	F	2026	1	SiSU	AC		ATIVO	Chapecó	1730	Pedagogia	Matutino	2018/1	2026-05-18T02:30:16.000Z
8	8	REGULAR	Branco	M	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		CANCELADO	Chapecó	1310	Engenharia Civil	Matutino e Vespertino	2025/2	2026-05-18T02:30:16.000Z
9	9	REGULAR	Indígeno	M	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		ATIVO	Chapecó	1310	Engenharia Civil	Matutino e Vespertino	2025/2	2026-05-18T02:30:16.000Z
10	10	REGULAR	Branco	M	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		ATIVO	Chapecó	1310	Engenharia Civil	Matutino e Vespertino	2025/2	2026-05-18T02:30:16.000Z
11	11	REGULAR	Indígeno	M	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		ATIVO	Chapecó	1310	Engenharia Civil	Matutino e Vespertino	2025/2	2026-05-18T02:30:16.000Z
12	12	REGULAR	Indígeno	M	2026	1	SiSU	AC		ATIVO	Chapecó	1301	Engenharia Ambiental E Sanitária	Matutino e Vespertino	2024/1	2026-05-18T02:30:16.000Z
13	13	REGULAR	Indígeno	F	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		ATIVO	Chapecó	1800	Letras - Português E Espanhol	Noturno	2020/1	2026-05-18T02:30:16.000Z
14	14	REGULAR	Branco	F	2026	1	PROCESSO SELETIVO SIMPLIFICADO	AC		ATIVO	Realeza	3602	Administração Pública	Noturno	2021/1	2026-05-18T02:30:16.000Z

Fonte: Portal de Dados Abertos da UFFS (2026).

- **Turmas Ofertadas:** Base responsável por catalogar toda a oferta de disciplinas da instituição ao longo dos semestres. Reúne colunas como o nome e o código do componente curricular (CCR), a carga horária da disciplina e o número de cursos para os quais a turma foi aberta. Do ponto de vista de modelagem relacional, este recurso fornece chaves primárias essenciais, apresentando os identifi-

cadores únicos gerados tanto pelo antigo sistema acadêmico (SGA) quanto pelo sistema atual (SIGAA).

Figura 2.2 – Amostra visual dos dados brutos do conjunto de dados de turmas ofertadas.



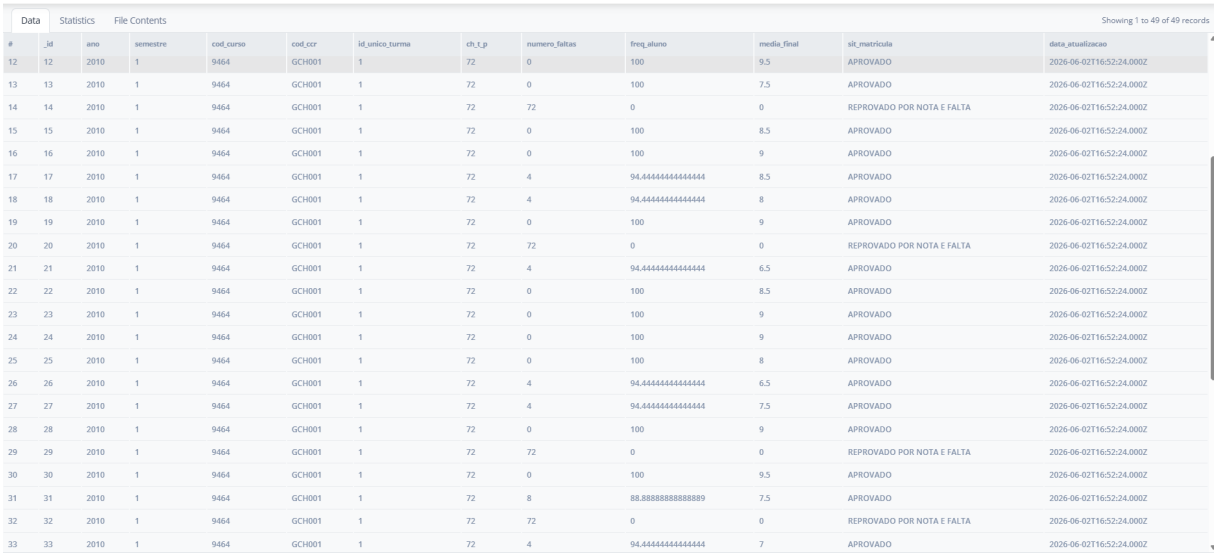
Data | Statistics | File Contents — Showing 1 to 50 of many records

cod_ccr	nome_ccr	ch_ccr	id_unico_turma	id_relativo_turma	quantidade_cursos	cod_uffs_cursos_turma	cursos_turma	quantidade_docentes	lista_docentes	lista_ch_docentes	vagas_turma	qtd_inscritos	qtd_passaram_pela_turma	qtd_aprovados	sit_turma
GCS001	INTRODUÇÃO À ADMINISTRAÇÃO	60	16	16	1	4520	DESENVOLVIMENTO RURAL E GESTÃO AGROINDUSTRIAL	1	LOUISE DE LIRA ROEDEL BOTELHO	60	50	69	69	59	CONSOLIDADA
GEX002	INTRODUÇÃO À INFORMÁTICA	60	38	38	1	4500	AGRONOMIA	1	RENEO PEDRO PREDIGER	60	50	48	48	43	CONSOLIDADA
GEX002	INTRODUÇÃO À INFORMÁTICA	60	39	39	1	4520	DESENVOLVIMENTO RURAL E GESTÃO AGROINDUSTRIAL	1	RENEO PEDRO PREDIGER	60	50	67	67	58	CONSOLIDADA
GEX002	INTRODUÇÃO À INFORMÁTICA	60	40	40	1	4300	ENGENHARIA AMBIENTAL E SANITÁRIA	1	IARA DENISE ENDRUWEIT BATTISTI	60	50	40	40	27	CONSOLIDADA
GLA008	LEITURA E EXPRESSÃO ESCRITA I	60	75	75	1	4500	AGRONOMIA	1	CRISTIANE HORST	60	50	49	49	47	CONSOLIDADA
GLA008	LEITURA E EXPRESSÃO ESCRITA I	60	76	76	1	4520	DESENVOLVIMENTO RURAL E GESTÃO AGROINDUSTRIAL	1	FRANCIELI SOCOLOSKI RODRIGUES	60	50	68	68	58	CONSOLIDADA
GLA008	LEITURA E EXPRESSÃO ESCRITA I	60	77	77	1	4300	ENGENHARIA AMBIENTAL E SANITÁRIA	1	FRANCIELI MATZENBACHER PINTON	60	50	43	43	29	CONSOLIDADA
GLA008	LEITURA E EXPRESSÃO ESCRITA I	60	78	78	1	4802	LETRAS - PORTUGUÊS E ESPANHOL	1	FRANCIELI SOCOLOSKI RODRIGUES	60	30	27	27	26	CONSOLIDADA
GEX001	MATEMÁTICA INSTRUMENTAL	60	113	113	1	4500	AGRONOMIA	1	ANA MARIA BASEI	60	50	49	49	32	CONSOLIDADA
GEX001	MATEMÁTICA INSTRUMENTAL	60	114	114	1	4520	DESENVOLVIMENTO RURAL E GESTÃO AGROINDUSTRIAL	1	ANA MARIA BASEI	60	50	67	67	29	CONSOLIDADA
GEX001	MATEMÁTICA INSTRUMENTAL	60	115	115	1	4300	ENGENHARIA AMBIENTAL E SANITÁRIA	1	ANA MARIA BASEI	60	50	45	45	22	CONSOLIDADA

Fonte: Portal de Dados Abertos da UFFS (2026).

- **Histórico de Notas:** Atua diretamente como a tabela de fatos acadêmicos, registrando o desempenho pontual de cada estudante em cada turma cursada. Suas variáveis quantitativas englobam o número total de faltas do aluno, o percentual final de frequência, a média final obtida na disciplina e a situação final consolidada (indicando textualmente se o aluno foi aprovado ou reprovado).

Figura 2.3 – Amostra visual dos dados brutos do conjunto de dados de histórico de notas.



Data | Statistics | File Contents — Showing 1 to 49 of 49 records

#	_id	ano	semestre	cod_curso	cod_ccr	id_unico_turma	ch_t_p	numero_faltas	freq_aluno	media_final	sit_matricula	data_atualizacao
12	12	2010	1	9464	GCH001	1	72	0	100	9.5	APROVADO	2026-06-02T16:52:24.000Z
13	13	2010	1	9464	GCH001	1	72	0	100	7.5	APROVADO	2026-06-02T16:52:24.000Z
14	14	2010	1	9464	GCH001	1	72	72	0	0	REPROVADO POR NOTA E FALTA	2026-06-02T16:52:24.000Z
15	15	2010	1	9464	GCH001	1	72	0	100	8.5	APROVADO	2026-06-02T16:52:24.000Z
16	16	2010	1	9464	GCH001	1	72	0	100	9	APROVADO	2026-06-02T16:52:24.000Z
17	17	2010	1	9464	GCH001	1	72	4	94.44444444444444	8.5	APROVADO	2026-06-02T16:52:24.000Z
18	18	2010	1	9464	GCH001	1	72	4	94.44444444444444	8	APROVADO	2026-06-02T16:52:24.000Z
19	19	2010	1	9464	GCH001	1	72	0	100	9	APROVADO	2026-06-02T16:52:24.000Z
20	20	2010	1	9464	GCH001	1	72	72	0	0	REPROVADO POR NOTA E FALTA	2026-06-02T16:52:24.000Z
21	21	2010	1	9464	GCH001	1	72	4	94.44444444444444	6.5	APROVADO	2026-06-02T16:52:24.000Z
22	22	2010	1	9464	GCH001	1	72	0	100	8.5	APROVADO	2026-06-02T16:52:24.000Z
23	23	2010	1	9464	GCH001	1	72	0	100	9	APROVADO	2026-06-02T16:52:24.000Z
24	24	2010	1	9464	GCH001	1	72	0	100	9	APROVADO	2026-06-02T16:52:24.000Z
25	25	2010	1	9464	GCH001	1	72	0	100	8	APROVADO	2026-06-02T16:52:24.000Z
26	26	2010	1	9464	GCH001	1	72	4	94.44444444444444	6.5	APROVADO	2026-06-02T16:52:24.000Z
27	27	2010	1	9464	GCH001	1	72	4	94.44444444444444	7.5	APROVADO	2026-06-02T16:52:24.000Z
28	28	2010	1	9464	GCH001	1	72	0	100	9	APROVADO	2026-06-02T16:52:24.000Z
29	29	2010	1	9464	GCH001	1	72	72	0	0	REPROVADO POR NOTA E FALTA	2026-06-02T16:52:24.000Z
30	30	2010	1	9464	GCH001	1	72	0	100	9.5	APROVADO	2026-06-02T16:52:24.000Z
31	31	2010	1	9464	GCH001	1	72	8	88.88888888888889	7.5	APROVADO	2026-06-02T16:52:24.000Z
32	32	2010	1	9464	GCH001	1	72	72	0	0	REPROVADO POR NOTA E FALTA	2026-06-02T16:52:24.000Z
33	33	2010	1	9464	GCH001	1	72	4	94.44444444444444	7	APROVADO	2026-06-02T16:52:24.000Z

Fonte: Portal de Dados Abertos da UFFS (2026).

2.2 Engenharia de Dados

A Engenharia de Dados é a disciplina focada na construção, manutenção e otimização de infraestruturas que permitem a coleta, o armazenamento e a transformação de dados em larga escala. Seu objetivo primário é garantir que os dados brutos sejam convertidos em formatos confiáveis e acessíveis para as equipes de análise, como analistas e cientistas de dados (REIS; HOUSLEY, 2022).

Historicamente, o processamento de dados era dominado pelo paradigma ETL (*Extract, Transform, Load*), no qual dados estruturados eram extraídos de sistemas transacionais, transformados em servidores intermediários e, por fim, carregados em repositórios (*data warehouses*). No entanto, com a explosão do volume, da velocidade e da variedade dos dados, aliada ao surgimento da computação em nuvem, o paradigma evoluiu para o modelo ELT (*Extract, Load, Transform*) (REIS; HOUSLEY, 2022).

2.2.1 Modern data stack e o paradigma ELT

O paradigma ELT constitui um dos pilares da arquitetura tecnológica denominada *modern data stack* (MDS). A MDS caracteriza-se como um conjunto de ferramentas nativas em nuvem, fundamentadas no modelo de *Software as a Service*

(SaaS) e em repositórios flexíveis de armazenamento, que apresentam capacidade de escalabilidade elástica (REIS; HOUSLEY, 2022). Sob esse paradigma, os dados são extraídos das fontes originais e carregados em seu estado bruto diretamente no repositório em nuvem, postergando a etapa de processamento.

Historicamente, o processamento analítico dependia de soluções monolíticas proprietárias, altamente acopladas e de custo elevado. A ascensão da *modern data stack* representa uma ruptura com esse modelo ao propor uma abordagem modular. Nesse formato, o *pipeline* é construído pela integração de ferramentas de código aberto ou serviços gerenciados especializados para cada etapa isolada do ciclo de vida dos dados — como ingestão, armazenamento, transformação, orquestração e visualização (REIS; HOUSLEY, 2022). Essa modularidade, somada à abstração do gerenciamento de servidores, transfere o foco das equipes de engenharia da manutenção de infraestrutura para a modelagem analítica e a geração de valor de negócio.

Dessa forma, as transformações (*transform*) ocorrem no próprio destino, aproveitando o poder computacional elástico e distribuído da nuvem (KLEPPMANN, 2017). Essa abordagem provê maior agilidade ao ciclo de desenvolvimento, visto que desacopla o processo de ingestão da lógica de negócio, reduzindo gargalos de processamento intermediários e conferindo flexibilidade para a manutenção ou evolução das regras de tratamento de dados (REIS; HOUSLEY, 2022).

2.2.2 Arquitetura medalhão

Para gerenciar a complexidade das transformações de dados dentro de um *data lake* moderno, o modelo conceitual mais adotado pela indústria é a arquitetura medalhão (*Medallion Architecture*), amplamente popularizada pela empresa Databricks (DATABRICKS, 2026). Esse padrão de arquitetura propõe a organização lógica do repositório em camadas de qualidade progressiva:

- **Camada Bronze (*raw*):** É a primeira camada de dados, armazenando-os em seu estado bruto exatamente como foram extraídos das fontes originais. O objetivo dessa camada é garantir a persistência imutável dos dados e viabilizar a reconstituição do histórico em caso de falhas, eliminando a necessidade de reconsultar a fonte primária.
- **Camada *Silver* (*cleansed*):** Constitui a zona de tratamento, enriquecimento e padronização. Nela, os dados da camada Bronze são consumidos e submetidos a processos de limpeza (*data cleansing*), como deduplicação, formatação cro-

nológica, tipagem estrita e tratamento de registros nulos, provendo uma visão única e confiável das entidades de domínio.

- **Camada *Gold* (*curated*):** Representa a zona de negócio, projetada especificamente para o consumo analítico otimizado. Os dados são agregados, sumarizados e modelados — comumente em formatos como *Star Schema* ou *Data Marts* — para atender aos requisitos de inteligência de negócios (BI), geração de relatórios gerenciais ou alimentação de modelos de aprendizado de máquina.

A implementação da arquitetura medalhão assegura a governança, a rastreabilidade e a confiabilidade dos fluxos de dados, permitindo que diferentes perfis de usuários institucionais acessem a informação no nível de abstração mais adequado para as suas respectivas atividades analíticas (DATABRICKS, 2026).

2.2.3 Computação em nuvem

O advento da computação em nuvem (*cloud computing*) revolucionou a forma como as infraestruturas de TI são concebidas. O *National Institute of Standards and Technology* (NIST) define a nuvem como um modelo que permite o acesso ubíquo, conveniente e sob demanda a um conjunto compartilhado de recursos computacionais configuráveis (como redes, servidores, armazenamento e aplicativos) (MELL; GRANCE, 2011).

No contexto da Engenharia de Dados, a nuvem viabiliza a criação de *data lakes* elásticos e de baixo custo de armazenamento (*object storage*), substituindo a necessidade de aquisição e manutenção de infraestrutura *on-premise* (servidores físicos locais) (REIS; HOUSLEY, 2022). Contudo, a simples migração para a nuvem não isenta as equipes da responsabilidade de provisionar, configurar e atualizar sistemas operacionais. Para mitigar esse esforço de administração, o mercado de tecnologia evoluiu para o paradigma *serverless* (computação sem servidor) (CASTRO et al., 2019).

2.2.4 O paradigma *serverless*

O termo *serverless* não implica a ausência física de servidores, mas sim uma abstração total do gerenciamento dessa infraestrutura por parte do desenvolvedor. Em uma arquitetura *serverless*, o provedor de nuvem (como Amazon Web

Services — AWS, Google Cloud Platform — GCP ou Microsoft Azure) aloca os recursos computacionais dinamicamente e de forma escalável apenas quando o código é executado (CASTRO et al., 2019).

As principais vantagens da adoção de tecnologias *serverless* em infraestruturas de dados incluem (CASTRO et al., 2019):

- **Precificação sob demanda (*pay-as-you-go*):** Diferente de instâncias de máquinas virtuais tradicionais, que exigem o provisionamento prévio de capacidade e geram custos constantes independentemente do uso, os serviços *serverless* tarifam estritamente o tempo de execução do código e o volume de memória consumido. Esse modelo elimina o desperdício financeiro de recursos ociosos.
- **Escalabilidade automática:** A infraestrutura adapta-se dinamicamente ao volume da carga de trabalho. O provedor em nuvem provisiona o processamento necessário quase instantaneamente para lidar com picos de processamento, retornando automaticamente ao estado inativo (*scale to zero*) após a conclusão das tarefas, sem necessidade de intervenção manual.
- **Foco na lógica de negócio:** A abstração dos servidores elimina o esforço operacional associado ao gerenciamento da infraestrutura subjacente, como a aplicação de *patches* de segurança e atualizações de sistemas operacionais. Isso permite que o esforço de desenvolvimento seja direcionado exclusivamente à construção e à otimização dos *pipelines* de processamento e das regras de negócio.

Devido a essas características, a adoção de um modelo computacional *serverless* é a abordagem arquitetural ideal para o processamento de dados governamentais e educacionais contínuos abordados neste estudo de caso.

2.2.5 Processamento analítico e armazenamento colunar

Para que a arquitetura medalhão opere de forma eficiente, especialmente nas camadas *Silver* e *Gold*, onde as agregações matemáticas e o enriquecimento dos dados ocorrem, é necessário utilizar *engines* de processamento e formatos de dados otimizados para leitura massiva.

Historicamente, os sistemas tradicionais foram projetados sob a arquitetura OLTP (*Online Transaction Processing*), sendo otimizados para inserções rápidas (linha a linha). No entanto, consultas analíticas que exigem a varredura de milhões de

registros sofrem degradação severa de performance quando lidas de forma transacional (KLEPPMANN, 2017).

Para solucionar esse gargalo, a Engenharia de Dados moderna utiliza a arquitetura OLAP (*Online Analytical Processing*), frequentemente materializado por meio de armazenamento colunar. Em vez de gravar os dados por linhas (como em arquivos CSV), formatos colunares (como o Apache Parquet) armazenam todos os valores de uma mesma coluna de forma contígua no disco. Isso permite que algoritmos de compressão reduzam drasticamente o tamanho dos arquivos e que o motor de busca processe apenas as colunas necessárias para uma agregação, descartando o restante da tabela (KLEPPMANN, 2017). A união de arquivos colunares com o processamento de *dataframes* em memória substitui a necessidade de manter bancos de dados tradicionais ativos em tempo integral, reduzindo custos e latência (REIS; HOUSLEY, 2022).

2.2.6 Orquestração de *pipelines* e arquiteturas orientadas a eventos

Na Engenharia de Dados, a movimentação de dados entre as camadas da arquitetura medalhão não ocorre de forma isolada; ela depende de um fluxo de execução coordenado. A orquestração é responsável por agendar, acionar, monitorar e gerenciar as dependências entre as diversas tarefas de extração, transformação e carga (REIS; HOUSLEY, 2022).

Embora a abordagem padrão da indústria muitas vezes envolva a modelagem desses fluxos em plataformas baseadas em grafos acíclicos direcionados (como o Apache Airflow), essas ferramentas exigem infraestrutura robusta e dedicada (REIS; HOUSLEY, 2022). Em contrapartida, arquiteturas modernas em nuvem têm adotado modelos de orquestração orientados a eventos (*event-driven*). Nesse modelo, os *pipelines* são acionados por gatilhos temporais (agendadores cronológicos) ou por eventos de sistema (como a chegada de um novo arquivo no *data lake*), invocando funções de computação *serverless* apenas no momento necessário (CASTRO et al., 2019). Essa abordagem garante tolerância a falhas e isolamento de processos com um custo de infraestrutura drasticamente reduzido (REIS; HOUSLEY, 2022; CASTRO et al., 2019).

2.2.7 Processamento vetorizado e o padrão Apache Arrow

Outro avanço significativo que viabiliza o alto desempenho da *modern data stack* é a padronização da representação de dados na memória RAM. Historicamente, a movimentação de dados entre diferentes ferramentas analíticas e linguagens de programação exigia processos custosos de serialização e desserialização, gerando alto consumo de memória e estrangulamento de CPU (REIS; HOUSLEY, 2022).

Atualmente, tecnologias de ponta em engenharia de dados adotam o Apache Arrow, um formato de memória colunar padronizado e independente de linguagem (APACHE SOFTWARE FOUNDATION, 2026). O uso de bibliotecas de manipulação de dados construídas nativamente sobre esse formato permite o processamento vetorizado, no qual operações matemáticas ou filtragens são aplicadas a blocos inteiros de dados simultaneamente, em vez de linha a linha (KLEPPMANN, 2017). Essa abordagem reduz severamente o uso de memória do servidor e acelera drasticamente o tratamento de grandes volumes de dados antes que eles sejam persistidos no *data lake* (REIS; HOUSLEY, 2022; KLEPPMANN, 2017).

2.2.8 Detalhamento das tecnologias adotadas

Para a concretização da arquitetura proposta, faz-se necessária a seleção de um conjunto de ferramentas que materialize os conceitos de processamento vetorizado, automação orientada a eventos e desacoplamento analítico. As tecnologias adotadas neste estudo de caso compreendem exclusivamente soluções de código aberto e serviços em nuvem com planos gratuitos permanentes, viabilizando a sustentabilidade operacional do pipeline sem custos recorrentes para a instituição:

- **Cloudflare R2 (*Object Storage*):** É um serviço de armazenamento de objetos gerenciado pela Cloudflare, projetado para armazenar e recuperar qualquer volume de dados de forma escalável e duradoura. Sua principal vantagem em relação a alternativas de mercado reside na ausência total de cobrança por transferência de dados de saída (*egress*), além de oferecer 10 GB de armazenamento e 10 milhões de operações de leitura gratuitas por mês de forma permanente. A API do R2 é compatível com o padrão S3 da Amazon Web Services, o que garante ampla interoperabilidade com bibliotecas e ferramentas do domínio de engenharia de dados, como o DuckDB (CLOUDFLARE, 2026). O R2 atua como

a fundação física do *data lake*, hospedando os arquivos das camadas Bronze, Silver e Gold da arquitetura medalhão.

- **GitHub Actions:** É uma plataforma de automação integrada ao GitHub que permite a execução de fluxos de trabalho (*workflows*) em resposta a eventos de repositório ou a agendamentos cronológicos definidos pela sintaxe *cron*. Em repositórios públicos, a plataforma oferece minutos de execução gratuitos de forma permanente (GITHUB, 2026). Nesta arquitetura, o GitHub Actions desempenha simultaneamente os papéis de motor de execução *serverless* — invocando os *scripts* Python com a biblioteca Polars para extração, transformação e persistência dos dados — e de orquestrador temporal.

- **Python:** É uma linguagem de programação de alto nível, interpretada e multiparadigma. A sua escolha como linguagem-base do projeto justifica-se pela sua consolidação como o padrão da indústria para Engenharia de Dados, possuindo um vasto acervo de bibliotecas otimizadas para manipulação analítica e compatibilidade nativa tanto com os ambientes de execução em nuvem utilizados quanto com os *frameworks* de desenvolvimento *web* adotados (PYTHON SOFTWARE FOUNDATION, 2026).

- **Polars:** É uma biblioteca de manipulação de dados (*dataframes*) de código aberto, escrita nativamente em Rust e projetada para processamento de alto desempenho. O Polars diferencia-se de ferramentas tradicionais (como o Pandas) por implementar execução vetorizada e paralela diretamente na CPU, além de utilizar o Apache Arrow como sua especificação de memória, otimizando a leitura e a transformação de grandes volumes de arquivos colunares (POLARS, 2026).

- **DuckDB:** É um sistema de gerenciamento de banco de dados relacional embarcado e de código aberto, otimizado especificamente para processamento analítico (OLAP). Executa de forma vetorizada dentro do próprio processo da aplicação, dispensando a arquitetura cliente-servidor tradicional. Sua grande vantagem técnica reside na capacidade de executar consultas SQL complexas diretamente sobre arquivos Parquet hospedados remotamente, sem a necessidade de ingestão prévia para tabelas locais (DUCKDB, 2026).

- **FastAPI:** É um *framework web* moderno, de alto desempenho e de código aberto, baseado em Python para a construção de APIs (*Application Programming Interfaces*). Utiliza padrões baseados em *type hints* nativos do Python e assincronismo (`async/await`), garantindo velocidades de execução comparáveis a linguagens

como Node.js e Go, além de gerar documentações interativas de rotas automaticamente via OpenAPI (FASTAPI, 2026).

- **Render:** É uma plataforma de computação em nuvem do tipo Plataforma como Serviço (PaaS), que simplifica o processo de implantação e hospedagem de aplicações *web*. Nesse contexto, a ferramenta atua na hospedagem contínua das interfaces e rotas, oferecendo integração direta de CI/CD (Integração e Entrega Contínuas) com os repositórios do código-fonte, gerenciando automaticamente o provisionamento da infraestrutura subjacente e os certificados de segurança (RENDER, 2026).

- **Streamlit e Plotly:** O Streamlit é um *framework* de código aberto em Python projetado para transformar *scripts* de dados em aplicações *web* interativas e responsivas de forma acelerada, eliminando a complexidade do desenvolvimento *frontend* tradicional. Para a camada de visualização de dados, a aplicação integra a biblioteca Plotly, responsável pela renderização de gráficos interativos baseados em JavaScript, habilitando recursos nativos de *zoom*, filtros de tela cruzados e navegação multidimensional (*drill-down*) (STREAMLIT, 2026; PLOTLY, 2026).

- **UptimeRobot:** É um serviço de monitoramento de disponibilidade que realiza verificações periódicas de *endpoints* HTTP, notificando o responsável em caso de falha. Seu plano gratuito permanente permite o monitoramento de até 50 serviços com intervalos de cinco minutos entre as verificações (UPTIMEROBOT, 2026). No contexto desta arquitetura, o UptimeRobot desempenha uma função estratégica de disponibilidade: ao realizar *pings* periódicos na rota de verificação de saúde (`/health`) da API FastAPI hospedada no Render, ele impede que o serviço entre no estado de suspensão por inatividade (*spin down*) característico do plano gratuito daquela plataforma, garantindo respostas imediatas ao painel analítico sem latências de inicialização (*cold start*).

2.3 O domínio do negócio: indicadores institucionais e educacionais

A Engenharia de Dados não é um fim em si mesma, mas um meio tecnológico para otimizar o domínio de negócio em que está inserida (REIS; HOUSLEY, 2022). No contexto de Instituições de Ensino Superior (IES) públicas, o “negócio” refere-se à gestão acadêmica, administrativa e de fomento. O processamento de dados governamentais visa apoiar a governança universitária e o controle social por

meio da geração de indicadores educacionais consistentes. A modelagem analítica desses indicadores permite que a coordenação pedagógica e a direção de unidades específicas, como o *campus* Chapecó, tomem decisões estratégicas baseadas em evidências (UNIVERSIDADE FEDERAL DA FRONTEIRA SUL - UFFS, 2017).

2.3.1 Fluxo acadêmico: evasão, retenção e diplomação

O acompanhamento da trajetória do estudante, desde o seu ingresso até a sua saída da instituição, é fundamental para a avaliação da qualidade do ensino. O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) estabelece métricas oficiais para acompanhar esse fluxo na educação superior, baseadas nas taxas de permanência, desistência e conclusão (INEP, 2017).

A evasão escolar, associada à taxa de desistência, ocorre quando o estudante abandona, é transferido ou é desvinculado do curso antes da sua conclusão. O fenômeno da evasão representa não apenas um desafio pedagógico, mas também um desperdício de recursos públicos e de esforço institucional (AMORIM; CASTELO BRANCO; DIAS JÚNIOR, 2025).

A retenção está intimamente ligada à permanência prolongada. Refere-se à situação em que o discente não consegue progredir no fluxo ideal do curso, estendendo seu vínculo além do período mínimo de integralização. A retenção é frequentemente causada por reprovações sucessivas em disciplinas específicas, conhecidas como “gargalos curriculares”. Em contrapartida, a diplomação, ou taxa de conclusão, mede o percentual de sucesso da coorte, ou seja, os ingressantes que efetivamente integralizaram os créditos e se formaram (INEP, 2017).

2.3.2 Perfil discente e políticas de permanência

Além do desempenho acadêmico, o mapeamento do perfil discente constitui um eixo vital da gestão universitária. A análise das modalidades de ingresso — como o impacto das diferentes categorias de cotas de inclusão social e racial — cruzada com os índices de aprovação e evasão fornece os dados necessários para o desenvolvimento e a calibração de políticas de assistência estudantil (AMORIM; CASTELO BRANCO; DIAS JÚNIOR, 2025). Compreender o perfil do estudante permite que a instituição direcione bolsas de estudo, monitorias e auxílios para os grupos

de maior vulnerabilidade acadêmica (AMORIM; CASTELO BRANCO; DIAS JÚNIOR, 2025; BRASIL, 2010).

3. TRABALHOS CORRELATOS

3.1 Abordagens de BI tradicional na gestão discente

No âmbito da gestão educacional pública, a utilização de ferramentas consolidadas de inteligência de negócios (*business intelligence*) tem sido o principal caminho adotado para a visualização de indicadores. Um exemplo direto dessa aplicação é o trabalho de Lopes (2023), que desenvolveu um *dashboard* gerencial focado no corpo discente da Faculdade de Ciências, Tecnologia e Educação da UNESP, no *campus* de Ourinhos. O objetivo da pesquisa foi transformar registros acadêmicos brutos em informações visuais que facilitassem a análise do histórico do curso, mapeando desde o desempenho individual até variantes sociodemográficas.

Sob o aspecto tecnológico, a solução proposta por Lopes (2023) utilizou o Microsoft Power BI como motor analítico central. A ferramenta foi responsável tanto pela modelagem das informações quanto pela renderização da interface gráfica final, consolidando gráficos dinâmicos de frequência e aproveitamento médio dos estudantes de forma interativa. O autor destaca que essa consolidação visual propicia múltiplas investigações cruzadas pelas comissões de curso.

Apesar do notável avanço na governança universitária proporcionado por projetos dessa natureza, trabalhos pautados estritamente em plataformas proprietárias tendem a herdar limitações arquiteturais. Tais soluções dependem de ambientes fechados, frequentemente exigindo licenças comerciais (como o Power BI Pro) para o compartilhamento seguro dos painéis na nuvem institucional, gerando custos recorrentes. Em contrapartida, a arquitetura proposta nesta monografia mitiga esse obstáculo ao adotar uma abordagem fundamentada em código aberto (*open-source*) e no isolamento de componentes. A utilização do Streamlit acoplado ao DuckDB e à FastAPI provê uma flexibilidade de hospedagem modular, garantindo a entrega do mesmo valor gerencial alcançado por Lopes (2023), porém com uma infraestrutura totalmente controlável e aderente à realidade orçamentária do sistema de ensino federal.

3.2 Processamento de dados educacionais via ETL tradicional

A necessidade de extrair, higienizar e disponibilizar grandes volumes de dados governamentais de instituições de ensino superior tem motivado a criação de rotinas automatizadas de integração. Nesse contexto, Rodrigues e Maciel (2022) pro-

puseram um método para a mineração e transformação de dados públicos brutos da Universidade Federal de Mato Grosso (UFMT), convertendo-os em Dados Abertos Educacionais (DAE) de alta qualidade semântica. O foco do estudo consistiu em estruturar um fluxo de trabalho padronizado capaz de consumir a fonte de dados acadêmicos e prepará-los para publicação.

Para viabilizar a solução metodológica, os autores adotaram uma abordagem baseada no paradigma ETL. A implementação prática foi realizada utilizando a ferramenta de código aberto Pentaho Data Integration (Kettle), um *software desktop* amplamente conhecido na indústria. Valendo-se de programação visual e componentes parametrizáveis (como o *plugin* ETL4LOD+), os dados da UFMT percorreram um fluxo contínuo de entrada, sofreram transformações para adequação ao formato estruturado RDF e foram carregados para o consumo final.

Embora o uso de ferramentas visuais como o Pentaho acelere o desenvolvimento ao poupar a escrita de código, a dependência de arquiteturas *desktop* ou de servidores locais para orquestrar o ETL impõe gargalos severos de escalabilidade e manutenção. Diferentemente do modelo estático apresentado por Rodrigues e Maciel (2022), a arquitetura elaborada nesta pesquisa adota o paradigma moderno ELT amparado por computação em nuvem (*serverless*). A substituição de robustas ferramentas de integração tradicionais pela orquestração nativa em nuvem e orientada a eventos (GitHub Actions), acionando rotinas efêmeras de execução e processamento vetorizado em memória (Polars), assegura que o *pipeline* da UFFS processe milhares de registros consumindo uma fração da memória e garantindo alta disponibilidade sem os elevados custos associados a servidores dedicados de integração.

3.3 Analytics educacional com ferramentas *open-source* modernas

Avançando para ambientes de desenvolvimento mais modernos, observa-se a ascensão de bibliotecas em linguagem Python voltadas para a prototipagem rápida de aplicações de dados. Nesse cenário, Marques (2025) desenvolveu um estudo de caso focado na análise do rendimento acadêmico dos discentes do curso de Direito da Universidade Federal do Rio Grande do Norte (UFRN). Utilizando os registros do Portal de Dados Abertos da instituição, o autor construiu um *dashboard web* interativo voltado para a comunidade acadêmica e a coordenação de curso, visando auxiliar na avaliação da estrutura curricular, retenção e taxas de aprovação.

Para o desenvolvimento da solução, Marques (2025) adotou a linguagem Python tanto para a Análise Exploratória de Dados (EDA) quanto para a construção

da interface final, valendo-se do *framework* Streamlit. O resultado do trabalho foi a entrega de uma ferramenta ágil, contendo gráficos de evolução temporal, mapas de calor de frequência *versus* média e diagramas de coordenadas paralelas. Além disso, o autor publicou o painel em nuvem utilizando o Streamlit Community Cloud de forma a disponibilizar os indicadores publicamente via navegador *web*, demonstrando a viabilidade de infraestruturas gratuitas.

Apesar do alinhamento tecnológico com o presente estudo — que também adota o Streamlit para a camada de visualização —, a abordagem monolítica de Marques (2025) acopla as regras de negócio e o processamento dos *dataframes* diretamente no código do *frontend*. Essa prática, embora eficiente para escopos restritos a um único curso, sobrecarrega a memória do aplicativo caso haja a necessidade de expansão para toda a universidade. Como diferencial arquitetural, esta pesquisa soluciona esse gargalo de escala adotando o padrão *headless BI*. Ao delegar todo o esforço de processamento cruzado para um motor OLAP (DuckDB) encapsulado em uma API independente (FastAPI), o painel atua estritamente como uma camada passiva de consumo visual, garantindo respostas em milissegundos e permitindo que outros sistemas institucionais consumam os mesmos indicadores no futuro sem depender da interface gráfica.

3.4 Integração e consumo de dados via portais CKAN

No contexto da transparência governamental e educacional, a plataforma CKAN consolidou-se como o padrão tecnológico para a catalogação de dados abertos. Explorando essa infraestrutura, Nahuz (2023) propôs uma arquitetura de engenharia de dados visando a extração, a transformação e o carregamento de registros acadêmicos de diversas instituições públicas de ensino superior brasileiras. O objetivo central do estudo consistiu em unificar esses dados abertos, originalmente isolados, em um repositório padronizado de dados conectados (*Linked Data*).

Para operacionalizar o consumo das informações, a metodologia adotada por Nahuz (2023) baseou-se na construção de rotinas de extração automatizadas em linguagem Python. O autor implementou uma classe dedicada (denominada *CkanConsumer*) para explorar nativamente a API dos portais institucionais, realizando requisições HTTP aos *endpoints* governamentais para obter os dados brutos diretamente no formato JSON. Essa abordagem programática acelera significativamente a obtenção de informações quando comparada ao *download* manual pelas interfaces *web*.

Apesar de o trabalho referenciado validar com êxito a viabilidade técnica da integração via API com repositórios CKAN, a orquestração do *pipeline* proposto por Nahuz (2023) dependia da implantação do Apache Airflow em contêineres Docker acoplados a bancos de dados não relacionais (MongoDB). Essa arquitetura, embora robusta, exige provisionamento contínuo e manutenção de infraestrutura dedicada. Como diferencial metodológico, o presente estudo soluciona esse desafio de complexidade operacional e de custos por meio da automação puramente *serverless*. Ao acoplar a API do CKAN da UFFS a um fluxo orquestrado nativamente pelo GitHub Actions, os *scripts* de extração baseados na biblioteca Polars garantem a atualização contínua do *data lake* sem a necessidade de instanciar ou de administrar servidores de orquestração.

4. METODOLOGIA

4.1 Caracterização da pesquisa

Esta pesquisa classifica-se, quanto à sua natureza, como aplicada e, quanto aos seus objetivos, como exploratória. É classificada como aplicada pois busca gerar conhecimentos para aplicação prática e dirigida à solução de problemas específicos (PRODANOV; FREITAS, 2013), neste caso, a gestão universitária, por meio do desenvolvimento de artefatos tecnológicos (um *pipeline* de Engenharia de Dados e um painel analítico). Adicionalmente, caracteriza-se como exploratória por ter como objetivo principal proporcionar maior familiaridade com o problema, visando torná-lo mais explícito (GIL, 2017), devido à necessidade inicial de descobrir e estruturar padrões em bases de dados abertos governamentais. O estudo é delimitado ao escopo do *campus* Chapecó da Universidade Federal da Fronteira Sul (UFFS), com foco exclusivo no cruzamento de dados do domínio discente e do fluxo acadêmico.

4.2 Etapas da pesquisa

O desenvolvimento deste *pipeline* analítico institucional compreenderá oito fases sequenciais, cíclicas e interdependentes, alinhadas ao ciclo de vida da Engenharia de Dados contemporânea (REIS; HOUSLEY, 2022). Esse processo metodológico, que abrangerá desde a investigação exploratória inicial das bases públicas até a implantação automatizada e segura da solução em ambiente de nuvem, será composto pelas seguintes etapas:

- **i. Estudo exploratório e análise das bases de dados disponíveis:** Investigação inicial das estruturas de dados publicadas no Portal de Dados Abertos para identificação de colunas, chaves de relacionamento, volumetria e consistência dos dados.
- **ii. Definição da arquitetura da solução e *stack* de desenvolvimento:** Planejamento de engenharia focado na escolha das ferramentas e na definição do *design* arquitetural sob os paradigmas *lakehouse*, *serverless* e *headless BI*.
- **iii. Gerenciamento de riscos:** Estabelecimento de planos de contingência para volatilidade de dados.

- **iv. Ingestão de dados e tratamento de restrições de API:** Desenvolvimento de *scripts* automatizados para o consumo dos *endpoints* REST do CKAN, implementando lógicas de paginação para contornar os limites nativos da fonte.
- **v. Tratamento, limpeza e armazenamento persistente (camadas Bronze e *Silver*):** Aplicação de rotinas de limpeza, deduplicação, tipagem e particionamento físico de arquivos colunares Parquet no *object storage* Cloudflare R2, utilizando processamento vetorizado em memória.
- **vi. Modelagem analítica e consolidação da camada de serviço (camada *Gold*):** Agregação das regras de negócio educacionais e isolamento das métricas em *data marts* analíticos, que serão consultados via motor OLAP embarcado DuckDB e expostos por rotas na FastAPI.
- **vii. Construção e hospedagem do painel analítico:** Desenvolvimento da interface gráfica gerencial utilizando o *framework* Streamlit enriquecido com gráficos interativos em Plotly, com implantação contínua e hospedagem em nuvem gerenciada (Render).
- **viii. Orquestração, automação e observabilidade do *pipeline*:** Configuração de gatilhos cronológicos orientados a eventos via GitHub Actions para o acionamento de rotinas de extração, com monitoramento de disponibilidade e rastreabilidade de falhas que serão garantidos por serviços de verificação contínua, como o UptimeRobot.

A seguir, cada uma das etapas apresentadas será descrita e detalhada em suas respectivas subseções técnicas, fundamentando as decisões de implementação que serão adotadas na construção do artefato.

4.2.1 Estudo exploratório e análise das bases de dados disponíveis

A primeira etapa metodológica da pesquisa consistiu na investigação do catálogo de dados abertos disponibilizado no portal da instituição. Por meio de uma abordagem de Análise Exploratória de Dados (EDA — *Exploratory Data Analysis*) (MCKINNEY, 2022), o foco inicial foi mapear os recursos tabulares essenciais para a modelagem do escopo acadêmico, compreendendo as estruturas dos conjuntos de perfil discente, turmas ofertadas e histórico de notas.

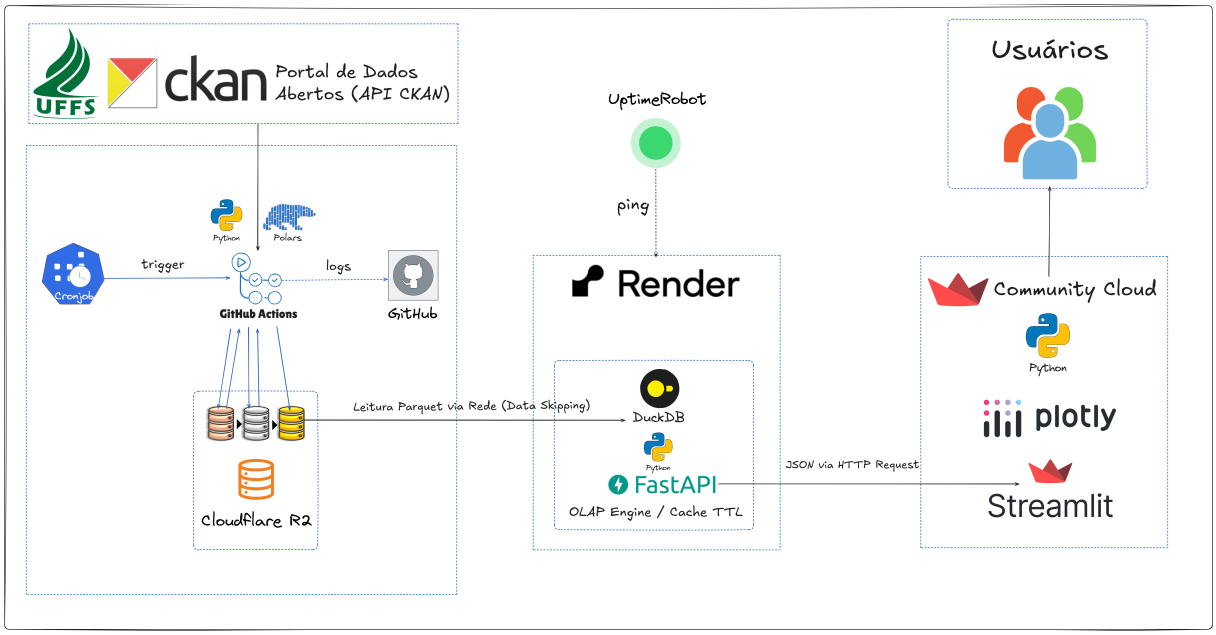
Nessa fase, realizou-se a inspeção técnica dos dados fornecidos pela plataforma CKAN para atestar a granularidade das informações e identificar as chaves

relacionais candidatas que permitiriam o cruzamento futuro entre as tabelas. Além disso, o estudo exploratório preliminar mostrou-se fundamental para diagnosticar precocemente o comportamento dos dados brutos, mapeando a presença de valores nulos, inconsistências de tipagem, limitações de volumetria e restrições de consumo da fonte (REIS; HOUSLEY, 2022). O resultado dessa investigação forneceu as informações necessárias para o desenho das rotinas de extração e das regras de limpeza que compõem as camadas de processamento do ambiente analítico.

4.2.2 Definição da arquitetura da solução e *stack* de desenvolvimento

Para compreender de forma integrada o fluxo dos dados e a interconexão das tecnologias que compõem este *pipeline* analítico institucional, a Figura 4.1 ilustra a arquitetura de referência proposta para o projeto. A solução será implementada sob o paradigma *lakehouse*, utilizando processamento *serverless* e uma camada de visualização completamente desacoplada baseada no conceito de *headless BI* (REIS; HOUSLEY, 2022).

Figura 4.1 – Diagrama da arquitetura de dados e serviços do *pipeline* analítico.



Fonte: Desenvolvido pelo autor

Como demonstrado no diagrama, a arquitetura está estruturada em quatro zonas operacionais com responsabilidades bem delimitadas. O fluxo iniciará na camada de origem (API CKAN da UFFS), transitando para a infraestrutura de armazenamento em nuvem, onde ocorrerá a ingestão, o tratamento via biblioteca Polars e a

persistência nas camadas da arquitetura medalhão no Cloudflare R2 (Bronze, *Silver* e *Gold*). A execução e o agendamento dessas rotinas serão gerenciados pelo GitHub Actions por meio de *workflows* executados periodicamente por agendamentos cron, que executam os *scripts* Python em ambiente de execução hospedado pelo GitHub, com rastreabilidade de execuções por meio dos *logs* nativos da plataforma.

A distribuição das métricas irá ocorrer de forma isolada na plataforma Render por meio de rotas RESTful na FastAPI, utilizando o motor OLAP embarcado DuckDB para realizar consultas SQL vetorizadas e de baixo custo computacional diretamente sobre os arquivos Parquet hospedados no Cloudflare R2. O monitoramento da disponibilidade será realizado pelo UptimeRobot, que efetuará requisições periódicas à API em intervalos de cinco minutos, contribuindo para a manutenção da disponibilidade do serviço e para a detecção de indisponibilidades. Por fim, o consumo analítico será efetuado na interface responsiva desenvolvida em Streamlit com gráficos dinâmicos em Plotly, cuja hospedagem será sustentada de forma gratuita no Streamlit Community Cloud. As seções subsequentes detalham os procedimentos metodológicos, algoritmos e restrições técnicas de cada uma dessas etapas.

4.2.3 Gerenciamento de riscos

O desenvolvimento de arquiteturas analíticas fundamentadas em dados abertos e serviços em nuvem está sujeito a riscos operacionais, como a descontinuidade da fonte primária e as restrições de infraestrutura de terceiros. Para mitigar o risco de instabilidade ou atrasos no fornecimento das bases de dados no portal CKAN da instituição, estabelece-se como plano de contingência primário o acionamento administrativo por meio dos canais oficiais da Lei de Acesso à Informação (plataforma Fala.BR). Paralelamente, para contornar as limitações inerentes à adoção de ambientes de nuvem em planos gratuitos, o projeto define diretrizes de cibersegurança, controle de cotas e governança de credenciais, assegurando a viabilidade técnica e a estabilidade da solução.

4.2.3.1 Obtenção de dados via Lei de Acesso à Informação (Fala.BR)

Durante a fase de levantamento bibliográfico e estudo exploratório no Portal de Dados Abertos da UFFS, identificou-se a existência do dicionário de dados referente ao conjunto “Histórico de Graduação”. No entanto, o arquivo bruto correspondente encontrava-se temporariamente indisponível para consumo ou descontinuado na plataforma.

Para superar essa limitação técnica e assegurar a viabilidade das análises de fluxo acadêmico, foi formalizada uma requisição na Plataforma Integrada de Ouvidoria e Acesso à Informação (Fala.BR) no dia 17 de maio de 2026, registrada sob o NUP 23546.064378/2026-17. Amparada pela Lei de Acesso à Informação (Lei nº 12.527/2011) (BRASIL, 2011), a manifestação solicitou a extração da base histórica contendo os registros de faltas, médias e situação dos estudantes por componente curricular.

A solicitação foi atendida e o acesso foi concedido pelo Serviço de Informação ao Cidadão (SIC) da UFFS no dia 8 de junho de 2026. O órgão informou que, a partir da abertura do chamado, foi realizada uma correção nas rotinas de coleta de dados das bases institucionais. Com a intervenção, o conjunto de dados foi integralmente restabelecido, atualizado e disponibilizado de forma pública por meio de um *link* direto no portal, permitindo o prosseguimento seguro da ingestão de dados e o desenvolvimento do *pipeline* analítico.

4.2.3.2 Segurança de infraestrutura e governança de recursos em nuvem

Para garantir a segurança da camada de serviço e o respeito aos limites de cota dos planos gratuitos, a arquitetura contemplará mecanismos de autenticação entre microsserviços via chaves de API (*API Keys*). Adicionalmente, nenhuma credencial de acesso será exposta no código-fonte, adotando-se o uso de cofres de segredos (*secrets*) nativos das plataformas de orquestração e hospedagem para o gerenciamento das variáveis de ambiente.

4.2.4 Ingestão de dados e tratamento de restrições da API

Uma vez mapeadas as estruturas dos dados na etapa exploratória preliminar, o processo metodológico de desenvolvimento da solução iniciará pela camada de ingestão. A extração dos três conjuntos de dados delimitados para esta pesquisa (Perfil Discente, Turmas Ofertadas e Histórico de Graduação) não será realizada por meio do *download* manual de arquivos estáticos, mas sim de forma automatizada via requisições HTTP, consumindo a API REST do Portal de Dados Abertos da UFFS (NAHUZ, 2023).

Executado em ambiente de nuvem por meio de *workflows* automatizados no GitHub Actions, o projeto utilizará o *endpoint* `datastore_search_sql` fornecido pela plataforma CKAN. Esse mecanismo permite submeter consultas baseadas na sintaxe

SQL diretamente na URL da requisição. Com isso, serão aplicados filtros de negócio diretamente na origem (como solicitar estritamente os registros vinculados ao *campus* Chapecó), poupando tráfego de rede e tempo de processamento desnecessários.

No entanto, como a API do CKAN impõe restrições técnicas, o desenvolvimento algorítmico exigirá os seguintes tratamentos:

- **Limite de registros por requisição (*pagination*):** A API limita nativamente o número máximo de linhas retornadas em uma única chamada. Para contornar essa restrição e garantir a extração das bases acadêmicas completas, será implementada uma lógica de paginação no *script* de ingestão em Python (NAHUZ, 2023). A automação utilizará parâmetros de deslocamento (*offset*) e limite (*limit*) em laços de repetição recursivos até que o último registro seja capturado.
- **Tratamento de *payload* JSON:** O retorno bruto da API, entregue no formato semiestruturado JSON, passará por uma etapa de conversão. O método propõe a transformação desse formato para estruturas tabulares alocadas em memória RAM (*dataframes*). Nessa etapa transitória, os dados passarão por uma checagem primária de integridade estrutural (validação de chaves e colunas) antes de serem encaminhados para a camada de armazenamento persistente.

4.2.5 *Pipeline* de tratamento e armazenamento (camadas Bronze e *Silver*)

Após a etapa de ingestão via API, o projeto seguirá o fluxo de qualidade progressiva proposto pela arquitetura medalhão (DATABRICKS, 2026). Esta seção descreve os procedimentos metodológicos que serão adotados para a persistência e o tratamento dos três conjuntos de dados estudantis coletados.

O primeiro ponto de persistência será a camada Bronze, consolidando a adoção do paradigma ELT (REIS; HOUSLEY, 2022). Nesse modelo, os dados brutos de Perfil Discente, Turmas Ofertadas e Histórico de Graduação, obtidos em formato JSON, serão extraídos e convertidos para arquivos Apache Parquet sem alterações em sua estrutura lógica ou conteúdo informacional. Esses arquivos constituirão a camada Bronze, preservando integralmente os registros originais em um formato colunar otimizado para armazenamento e processamento analítico. Esses arquivos serão armazenados no serviço de objetos Cloudflare R2, funcionando como uma zona de dados brutos imutáveis que garantirá a reprodutibilidade do *pipeline* em caso de falhas, dispensando novas requisições massivas à fonte.

Em seguida, o fluxo de transformação prosseguirá para a camada *Silver*. Essa etapa ocorrerá de forma sequencial no próprio ambiente de execução do GitHub Actions, utilizando *scripts* em Python ancorados na biblioteca Polars (POLARS, 2026). O Polars será empregado devido à sua capacidade de executar processamento vetorizado e paralelo diretamente na memória RAM. Os seguintes procedimentos serão aplicados:

- **Filtragem de escopo:** Aplicação de regras para isolar exclusivamente os registros vinculados ao *campus* Chapecó.
- **Tratamento de inconsistências:** Identificação e imputação de valores nulos (*NaN/null*) e remoção de registros duplicados.
- **Padronização e tipagem:** Conversão técnica de tipos de dados e uniformização de *strings* categóricas (como nomenclaturas de cotas e *status* de aprovação).

Concluída a limpeza, os dados da camada *Silver* serão novamente persistidos no Cloudflare R2 em arquivos Parquet. Para otimizar a leitura dos dados, será implementado o particionamento físico dos diretórios (KLEPPMANN, 2017). Essa estratégia permite que mecanismos de consulta, como o DuckDB, acessem apenas os subconjuntos relevantes dos dados, reduzindo a varredura de arquivos e melhorando o desempenho das consultas.

4.2.6 Modelagem analítica e camada de serviço (camada *Gold*)

A arquitetura proposta aproxima-se do paradigma *lakehouse*, que combina a flexibilidade e a escalabilidade de baixo custo de armazenamento dos *data lakes* com a estruturação, consistência e recursos analíticos tradicionalmente associados a *data warehouses* (REIS; HOUSLEY, 2022). Em oposição aos modelos monolíticos estritamente acoplados, a etapa de disponibilização e consumo dos dados adotará o padrão arquitetural de *headless BI* (*business intelligence* desacoplado). Nessa abordagem, as regras de negócio educacionais serão totalmente isoladas na camada de serviço, garantindo que a disponibilização das métricas permaneça desacoplada da interface gráfica de exibição.

A modelagem analítica consistirá na consolidação dos dados tratados da camada *Silver* em estruturas orientadas ao domínio de negócio. O resultado dessas operações formará a camada *Gold*, que será estruturada na forma de *data marts* analíticos departamentais em formato Apache Parquet, armazenados de forma persistente

e particionada no Cloudflare R2 (KLEPPMANN, 2017). Esses *data marts* responderão diretamente pelas regras de negócio institucionais, isolando indicadores como o cálculo de taxas de evasão cruzadas com modalidades de cotas e o agrupamento estatístico de reprovações para a identificação de gargalos curriculares.

Para prover o acesso a esses indicadores de forma ultraveloz, escalável e segura, será desenvolvido um microsserviço estruturado sob o *framework* FastAPI, em linguagem Python, hospedado na plataforma em nuvem Render (*platform as a service* – PaaS) (FASTAPI, 2026; RENDER, 2026). O grande diferencial técnico dessa camada será a incorporação do DuckDB como o motor analítico (OLAP) embarcado da aplicação (DUCKDB, 2026).

O DuckDB atuará como uma *engine* de processamento *serverless* e de alta performance (*lightweight*), eliminando a necessidade de provisionar, pagar e gerenciar a infraestrutura de um servidor de banco de dados tradicional ativo em tempo integral (DUCKDB, 2026). O fluxo operacional da camada de serviço ocorrerá da seguinte forma:

1. A FastAPI receberá os parâmetros de filtragem analítica enviados pelo usuário por meio de requisições HTTP *RESTful*;
2. O DuckDB interceptará esses parâmetros e executará consultas SQL vetorizadas diretamente sobre os arquivos Parquet armazenados no Cloudflare R2;
3. Por meio do mecanismo de *data skipping* nativo do formato colunar, o DuckDB lerá via rede estritamente os blocos de dados e as colunas necessárias para computar a resposta, poupando tráfego e processamento;
4. O resultado da agregação SQL será convertido instantaneamente em memória e serializado pela FastAPI para o formato leve e universal JSON.

Adicionalmente, para mitigar os tempos de inicialização (*cold starts*) característicos de contêineres no plano gratuito do Render e reduzir a latência de rede nas chamadas ao Cloudflare R2, o microsserviço utilizará estratégias de *cache* em memória. Serão implementados mecanismos de *time-to-live* (TTL), *lazy loading* (carregamento sob demanda) e *cache warming* (aquecimento prévio da memória RAM no momento da inicialização da API). Complementarmente, o serviço UptimeRobot realizará requisições periódicas à rota de verificação de saúde da API em intervalos de cinco minutos. Essa estratégia visa manter o servidor em estado ativo durante o horário comercial ou de maior acesso, reduzindo drasticamente a suspensão por inatividade (*spin down*). Embora a reciclagem periódica de instâncias seja uma limitação inerente aos planos gratuitos de nuvem, o emprego conjunto dessas técnicas

otimizará o desempenho geral do sistema. Dessa forma, espera-se que consultas analíticas repetitivas sejam respondidas com latência reduzida, frequentemente na casa dos milissegundos, conferindo alta eficiência computacional e responsividade à arquitetura analítica.

4.2.7 Desenvolvimento e hospedagem do painel analítico

A última etapa compreenderá a construção da interface gráfica para a visualização dos indicadores gerenciais. A aplicação será desenvolvida utilizando o *framework* de código aberto Streamlit, e sua publicação em ambiente de produção ocorrerá de forma totalmente gratuita por meio da plataforma Streamlit Community Cloud (STREAMLIT, 2026). A adoção dessa infraestrutura de hospedagem justifica-se pelo seu modelo de implantação contínua (*continuous deployment*) integrado nativamente à plataforma GitHub, além de prover o provisionamento isolado de recursos computacionais sem custos operacionais para a instituição pública de ensino.

O painel atuará estritamente como a camada de consumo visual desacoplada, operando de forma síncrona com a camada de serviço. Ao ser inicializada ou ao receber interações nos filtros dispostos na barra lateral (*sidebar*), a aplicação efetuará requisições HTTP direcionadas às rotas da FastAPI.

Para garantir uma camada analítica robusta, a renderização visual dos indicadores extraídos dos *data marts* via DuckDB utilizará a biblioteca gráfica Plotly (PLOTLY, 2026). A integração do Plotly permitirá a exploração avançada dos dados por meio de gráficos dinâmicos, com suporte nativo a recursos de *zoom*, filtragem cruzada entre componentes e *drill-down* (detalhamento progressivo da informação).

4.2.8 Orquestração, automação e observabilidade

O fluxo contínuo dos dados adotará uma orquestração orientada a eventos (*event-driven*) implementada por meio da plataforma GitHub Actions. A execução dos *pipelines* será acionada por agendadores cronológicos definidos em sintaxe *cron* nos arquivos de configuração do repositório, disparando os *workflows* de extração e transformação em janelas de baixa concorrência de rede (GITHUB, 2026).

O GitHub Actions atuará como o orquestrador central, executando a extração na API do CKAN, processando as transformações com a biblioteca Polars e persistindo os dados do *lakehouse* no Cloudflare R2. Por tratar-se de um repositório público,

a execução dos *workflows* se beneficia da ampla cota gratuita de minutos oferecida pela plataforma. O processamento vetorizado do Polars atuará como um mitigador crucial para evitar o esgotamento dos limites de memória RAM dos *runners* gratuitos, assegurando a sustentabilidade e a adequação da solução à realidade de infraestrutura enxuta do setor público.

Além da execução, a arquitetura contará com dois mecanismos complementares de observabilidade e disponibilidade. O rastreio das operações do *pipeline* será gerenciado pelos *logs* nativos do GitHub Actions, que registrarão de forma centralizada o histórico de execuções, os tempos de processamento e os erros ocorridos em cada etapa, permitindo uma resposta ágil em caso de indisponibilidade da fonte primária.

A busca pela maior disponibilidade da camada de serviço será apoiada pelo UptimeRobot, serviço de monitoramento externo que realizará requisições HTTP periódicas à rota `/health` da API FastAPI em intervalos de cinco minutos (UPTIMEROBOT, 2026). Essa estratégia cumprirá duas funções simultâneas: atuará para evitar a suspensão automática do servidor por inatividade (*spin down*), característica do plano gratuito do Render, e servirá como monitor de integridade, notificando o responsável por e-mail em caso de falha no serviço. Dado que o UptimeRobot opera de forma independente do repositório GitHub, sua execução não estará sujeita à política de desativação automática de agendamentos em repositórios sem atividade recente, viabilizando a continuidade do monitoramento mesmo após o encerramento das fases de desenvolvimento ativo do projeto.

Por fim, destaca-se um risco operacional inerente ao modelo de orquestração adotado: a plataforma GitHub desativa automaticamente os *workflows* com agendamento cronológico (*schedule*) em repositórios que não registrem atividade de *commits* por um período superior a 60 dias. Esse comportamento implica que, após o encerramento das fases de desenvolvimento ativo do projeto, o *pipeline* de atualização do *data lake* poderá ser silenciosamente interrompido sem qualquer notificação ao responsável. Como estratégia de mitigação, será incorporada ao próprio *workflow* de orquestração uma etapa de escrita periódica em um arquivo de registro (*keep-alive log*) no repositório, garantindo a geração de *commits* automáticos em intervalos regulares e, consequentemente, a continuidade ininterrupta dos agendamentos cronológicos mesmo em períodos de inatividade no desenvolvimento.

4.3 Definição das análises e métricas do painel

Para cumprir os objetivos analíticos desta pesquisa e prover utilidade prática à gestão do *campus* Chapecó, a interface gráfica que será desenvolvida no Streamlit estruturará os dados em três visões multidimensionais. A experiência de usabilidade será centrada na aplicação de filtros globais dispostos em uma barra lateral (*sidebar*), permitindo que o usuário selecione o curso específico e o recorte temporal (ano e semestre de ingresso). Essa abordagem fará com que todos os blocos gráficos da tela principal se adaptem dinamicamente por meio de requisições parametrizadas à API.

O painel analítico consolidará um total de nove análises principais, distribuídas de forma simétrica conforme o escopo de negócio detalhado a seguir.

4.3.1 Visão 1: retrato demográfico e ingresso

O objetivo desta dimensão será mapear o perfil socioeconômico e a representatividade do corpo discente que ingressa no *campus*.

- **Análise 1 – Distribuição de ingressantes por modalidade de cota:** Contagem volumétrica de estudantes agrupada pela variável de ações afirmativas, mapeando o preenchimento de vagas reservadas (L1 a L14) em comparação à ampla concorrência (AC).
- **Análise 2 – Evolução histórica de gênero e raça:** Cruzamento temporal das variáveis de gênero e raça ao longo dos anos de ingresso, permitindo identificar o comportamento da diversidade discente no *campus*.
- **Análise 3 – Mapeamento das formas de ingresso:** Agrupamento e contagem dos registros com base na via de entrada institucional, evidenciando a relevância de rotas alternativas como transferência externa, retorno de graduado e processos seletivos especiais.

4.3.2 Visão 2: fluxo acadêmico (evasão e retenção)

Essa dimensão servirá para diagnosticar quantitativamente os pontos de evasão e os padrões de desistência nos cursos de graduação.

- **Análise 4 – Taxa de evasão por curso:** Indicador percentual que calcula a proporção de estudantes com *status* de vínculo “Cancelado” ou “Desligado” em relação ao total de ingressantes da respectiva coorte (*cohort*).
- **Análise 5 – Evasão comparada por tipo de ingresso:** Cruzamento do índice de evasão com as modalidades de cota, visando monitorar se há maior vulnerabilidade ou necessidade de calibração nas políticas de assistência estudantil para determinados grupos.
- **Análise 6 – Curva de evasão histórica por ano de ingresso:** Gráfico temporal que demonstra o percentual acumulado de abandono de cada turma ingressante ao longo dos semestres, permitindo avaliar o impacto de eventos institucionais ou externos (como o período pandêmico) na retenção de fluxo.

4.3.3 Visão 3: desempenho e gargalos curriculares

Essa dimensão é dedicada a avaliar o fluxo pedagógico dentro das disciplinas, cruzando a oferta de turmas com o rendimento acadêmico consolidado.

- **Análise 7 – *Ranking* de gargalos curriculares:** Listagem dos dez componentes curriculares (CCRs) com os maiores índices históricos de reprovação absoluta, apontando criticamente os principais pontos de retenção do curso.
- **Análise 8 – Correlação entre frequência e média final:** Mapeamento estatístico do rendimento por nota confrontado com o percentual de presença do estudante, útil para avaliar se a reprovação se associa predominantemente ao absenteísmo ou à complexidade do conteúdo programático.
- **Análise 9 – Perfil qualitativo da reprovação:** Segmentação proporcional dos registros de insucesso acadêmico, dividindo-os estritamente entre reprovações por nota e reprovações por frequência, subsidiando planos de ação pedagógicos distintos para cada cenário.

4.3.4 Cláusula de flexibilização do escopo analítico

Por tratar-se de um projeto formalizado no escopo do Trabalho de Conclusão de Curso I (TCC I), a listagem das nove análises supracitadas atua como diretriz inicial

estabelecida para a validação da arquitetura de *software* e de engenharia de dados proposta.

Todavia, a execução prática e a manipulação dos dados tabulares programadas para o Trabalho de Conclusão de Curso II (TCC II) poderão revelar novos padrões latentes, comportamentos anômalos ou demandas específicas por parte das coordenações acadêmicas. Dessa forma, resguarda-se a flexibilidade metodológica para a inclusão, ajuste ou refinamento de métricas e visualizações adicionais no artefato final, desde que devidamente justificadas e documentadas no relatório conclusivo da pesquisa.

4.4 Declaração de uso de inteligência artificial

Em estrita conformidade com a Portaria CNPq nº 2.664/2026, que estabelece as diretrizes de integridade na pesquisa apoiada pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) (BRASIL, 2026a), declara-se o uso de ferramentas de inteligência artificial generativa (IAG) durante o desenvolvimento desta pesquisa.

A plataforma Gemini (Google) foi utilizada especificamente como ferramenta de apoio à revisão ortográfica e à estruturação da formatação do documento no sistema de tipografia LaTeX.

4.5 Gestão e disponibilização de dados e códigos

Em atendimento às boas práticas de ciência aberta e à diretriz de gestão transparente de dados, todos os artefatos tecnológicos desenvolvidos durante este projeto serão versionados e depositados em um repositório público de controle de versão (GitHub).

4.6 Cronograma de execução

O cronograma de execução estabelece a previsão temporal para o desenvolvimento integral desta pesquisa, englobando as fases exploratórias, arquiteturais e práticas distribuídas entre o Trabalho de Conclusão de Curso I (TCC I) e o Trabalho de Conclusão de Curso II (TCC II).

A Tabela 4.1 detalha a distribuição das atividades ao longo dos dois semestres letivos. O fluxo reflete as etapas metodológicas propostas, cobrindo desde a investigação inicial das bases públicas, até a construção contínua do *pipeline* analítico e a defesa definitiva perante a banca avaliadora.

Tabela 4.1 – Cronograma geral de atividades (TCC I e TCC II).

Atividades	**TCC I (1º Semestre)**					**TCC II (2º Semestre)**				
	Mar	**Abr**	**Mai**	**Jun**	**Jul**	**Ago**	**Set**	**Out**	**Nov**	**Dez**
Levantamento bibliográfico e revisão da literatura	X	X								
Etapa i. Estudo exploratório das bases de dados		X	X							
Etapa ii. Definição da arquitetura e *stack*			X	X						
Etapa iii. Gerenciamento de riscos				X						
Redação e revisão do documento (TCC I)	X	X	X	X	X					
Defesa perante a banca (TCC I)					X					
Etapa iv. Ingestão de dados via API CKAN						X				
Etapa v. Tratamento e persistência (Bronze/Silver)						X	X			
Etapa vi. Modelagem e camada de serviço (Gold)							X	X		
Etapa vii. Desenvolvimento do painel (Streamlit)								X	X	
Etapa viii. Orquestração e automação									X	
Redação e revisão do documento (TCC II)						X	X	X	X	X
Defesa perante a banca (TCC II)										X

REFERÊNCIAS BIBLIOGRÁFICAS

AMORIM, C. C.; CASTELO BRANCO, U. V.; DIAS JÚNIOR, J. J. L. Evasão e retenção no ensino superior: ampliando a compreensão teórico-metodológica. *Revista da FAEEBA – Educação e Contemporaneidade*, Salvador, v. 34, n. 79, p. 77–96, 2025. Disponível em: <https://doi.org/10.21879/faeeba2358-0194.2025.v34.n79.p77-96>. Acesso em: 7 jun. 2026.

APACHE SOFTWARE FOUNDATION. *Apache Arrow Documentation*. [S.l.], 2026. Disponível em: <https://arrow.apache.org/docs/>. Acesso em: 22 jun. 2026.

BRASIL. *Decreto nº 7.234, de 19 de julho de 2010. Dispõe sobre o Programa Nacional de Assistência Estudantil - PNAES*. Diário Oficial da União, 2010. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2007-2010/2010/decreto/d7234.htm>. Acesso em: 22 jun. 2026.

BRASIL. *Lei nº 12.527, de 18 de novembro de 2011. Regula o acesso a informações previsto no inciso XXXIII do art. 5º, no inciso II do §3ºdo art. 37 e no §2ºdo art. 216 da Constituição Federal*. Brasília, DF: Presidência da República, 2011. Disponível em: <http://www.planalto.gov.br/ccivil_03/_ato2011-2014/2011/lei/l12527.htm>. Acesso em: 3 maio 2026.

BRASIL. *Decreto nº 8.777, de 11 de maio de 2016. Institui a Política de Dados Abertos do Poder Executivo federal*. Brasília, DF: Presidência da República, 2016. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2016/decreto/d8777.htm>. Acesso em: 4 jun. 2026.

BRASIL. *Lei nº 13.709, de 14 de agosto de 2018. Dispõe sobre a Proteção de Dados Pessoais (LGPD)*. Brasília, DF: Presidência da República, 2018. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 7 jun. 2026.

BRASIL. *Decreto nº 9.903, de 8 de julho de 2019. Altera o Decreto nº 8.777, de 11 de maio de 2016, que institui a Política de Dados Abertos do Poder Executivo federal*. Brasília, DF: Presidência da República, 2019. Disponível em: <http://www.planalto.gov.br/ccivil_03/_ato2019-2022/2019/decreto/D9903.htm>. Acesso em: 10 maio 2026.

BRASIL. *Portaria CNPq nº 2.664, de 6 de março de 2026. Institui a Política de Integridade na Atividade Científica do CNPq*. Conselho Nacional de Desenvolvimento Científico e Tecnológico, 2026. Disponível em: <http://memoria2.cnpq.br/web/guest/view/-/journal_content/56_INSTANCE_0oED/10157/23142775>. Acesso em: 25 jun. 2026.

BRASIL. *Sobre Dados Abertos*. Portal Brasileiro de Dados Abertos, 2026. Disponível em: <https://www.gov.br/governodigital/pt-br/dados-abertos>. Acesso em: 10 maio 2026.

CASTRO, P. et al. The rise of serverless computing. *Communications of the ACM*, ACM New York, NY, USA, v. 62, n. 12, p. 44–54, 2019.

CKAN. *CKAN API Guide*. 2026. Disponível em: <https://docs.ckan.org/en/2.10/api/index.html>. Acesso em: 2 maio 2026.

CKAN BRASIL. *CKAN in Brazil*. CKAN, 2012. Disponível em: <https://ckan.org/blog/ckan-brazil>. Acesso em: 4 jun. 2026.

CLOUDFLARE. *Cloudflare R2 Object Storage Documentation*. 2026. Disponível em: <https://developers.cloudflare.com/r2/>. Acesso em: 21 jun. 2026.

DATABRICKS. *What is a Medallion Architecture?* 2026. Disponível em: <https://www.databricks.com/glossary/medallion-architecture>. Acesso em: 3 maio 2026.

DUCKDB. *DuckDB Documentation*. 2026. Disponível em: <https://duckdb.org/docs/>. Acesso em: 6 jun. 2026.

FASTAPI. *FastAPI Documentation*. 2026. Disponível em: <https://fastapi.tiangolo.com/>. Acesso em: 6 jun. 2026.

GIL, A. C. *Como elaborar projetos de pesquisa*. 6. ed. São Paulo: Atlas, 2017.

GITHUB. *GitHub Actions Documentation*. 2026. Disponível em: <https://docs.github.com/en/actions>. Acesso em: 21 jun. 2026.

INEP. *Metodologia de Cálculo dos Indicadores de Fluxo da Educação Superior*. Brasília, DF, 2017. Disponível em: <https://download.inep.gov.br/informacoes_estatisticas/indicadores_educacionais/2017/metodologia_indicadores_trajetoria_curso.pdf>. Acesso em: 10 maio 2026.

KLEPPMANN, M. *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. [S.l.]: O'Reilly Media, Inc., 2017.

LOPES, M. R. Transformando dados em informações: a ferramenta Power BI e a elaboração de dashboard sobre o corpo discente da FCTE – faculdade de ciências, tecnologia e educação da UNESP, câmpus de ourinhos. In: *Anais do II Congresso dos Profissionais das Universidades Estaduais de São Paulo (CONPUESP)*. Campinas, SP: Unicamp, 2023. p. e023186. Disponível em: <https://econtents.sbu.unicamp.br/eventos/index.php/conpuesp/article/view/4921>. Acesso em: 7 jun. 2026.

MARQUES, P. L. B. *Análise de rendimento acadêmico dos discentes da UFRN: um estudo de caso aplicado ao curso de direito*. Monografia (Trabalho de Conclusão de Curso (Bacharelado em Engenharia da Computação)) — Universidade Federal do Rio Grande do Norte, Natal, 2025. Disponível em: <https://repositorio.ufrn.br/items/aa9f04f3-bdc6-4077-9a83-12a8ba097087>. Acesso em: 7 jun. 2026.

MCKINNEY, W. *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter*. 3. ed. Sebastopol: O'Reilly Media, 2022.

MELL, P.; GRANCE, T. *The NIST definition of cloud computing*. Gaithersburg, MD, 2011. Disponível em: <https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-145.pdf>. Acesso em: 3 maio 2026.

NAHUZ, B. B. *Uma abordagem baseada em Engenharia de Dados para extração, transformação e carregamento de dados de instituições acadêmicas*. Monografia (Trabalho de Conclusão de Curso (Bacharelado em Engenharia da Computação)) — Universidade Federal do Maranhão, São Luís, 2023. Disponível em: <https://monografias.ufma.br/jspui/handle/123456789/7598>. Acesso em: 23 jun. 2026.

OPEN KNOWLEDGE FOUNDATION. *The Open Data Handbook*. 2012. Disponível em: <http://opendatahandbook.org/>. Acesso em: 2 maio 2026.

PLOTLY. *Plotly Python Graphing Library*. 2026. Disponível em: <https://plotly.com/python/>. Acesso em: 6 jun. 2026.

POLARS. *Polars Documentation: User Guide*. 2026. Disponível em: <https://docs.pola.rs/>. Acesso em: 6 jun. 2026.

PRODANOV, C. C.; FREITAS, E. C. d. *Metodologia do trabalho científico: métodos e técnicas da pesquisa e do trabalho acadêmico*. 2. ed. Novo Hamburgo: Universidade Feevale, 2013.

PYTHON SOFTWARE FOUNDATION. *Python 3 Reference Manual*. 2026. Disponível em: <https://docs.python.org/3/>. Acesso em: 7 jun. 2026.

REIS, J.; HOUSLEY, M. *Fundamentals of Data Engineering*. [S.l.]: O'Reilly Media, Inc., 2022.

RENDER. *Render Cloud Hosting Documentation*. 2026. Disponível em: <https://render.com/docs>. Acesso em: 7 jun. 2026.

RODRIGUES, F. A.; MACIEL, C. Um método para captura e compartilhamento de dados abertos educacionais via um processo ETL. In: *Anais do X Workshop de Computação Aplicada em Governo Eletrônico*. Porto Alegre, RS, Brasil: SBC, 2022. p. 133–144. ISSN 2763-8723. Disponível em: <https://sol.sbc.org.br/index.php/wcge/article/view/20717>. Acesso em: 7 jun. 2026.

STREAMLIT. *Streamlit Documentation*. 2026. Disponível em: <https://docs.streamlit.io/>. Acesso em: 6 jun. 2026.

UNIVERSIDADE FEDERAL DA FRONTEIRA SUL - UFFS. *Plano de Dados Abertos da UFFS*. Chapecó, SC: [s.n.], 2017. Disponível em: <https://boletim.uffs.edu.br/atos-normativos/instrucao-normativa/proplan/2017-0015>. Acesso em: 10 maio 2026.

UNIVERSIDADE FEDERAL DA FRONTEIRA SUL - UFFS. *Portal de Dados Abertos da UFFS*. 2026. Disponível em: <https://dados.uffs.edu.br/>. Acesso em: 3 maio 2026.

UPTIMEROBOT. *UptimeRobot: Free Website Monitoring*. 2026. Disponível em: <https://uptimerobot.com/>. Acesso em: 21 jun. 2026.